

# Conception et implémentation d'un compilateur pour le langage E

# 1 But de ces séances de travaux pratiques

Au cours de ces 5 séances de travaux pratiques, vous allez réaliser un compilateur pour un petit langage de programmation, le langage E. Le langage E est un dérivé du langage C. Nous nous concentrerons d'abord sur la compilation d'un version basique du langage E que nous enrichirons par la suite sur le temps additionnel. Votre compilateur sera composé d'un analyseur lexical (lexer), d'un analyseur syntaxique (parser), puis de plusieurs passes de compilation qui transformeront les programmes E dans des langages de plus en plus bas niveau, jusqu'à la génération de code assembleur x86-32 et RISC-V, qui seront finalement assemblés par des assembleurs existants et qui pourront être exécutés sur vos machines.

Comme nous allons le voir, le langage E est relativement petit, pour vous permettre de le réaliser dans le temps de TP qui vous est imparti. Cependant, il permet d'illustrer un grand nombre de concepts fondamentaux de la compilation. Au cas où vous trouveriez que le langage est trop petit, ou bien que les passes de compilation et d'optimisation suggérées ne sont pas suffisantes, nous vous fournirons une liste d'améliorations possibles que vous pourrez implémenter.

La Section 2 vous présente l'architecture du compilateur que vous allez concevoir, notamment les structures de données à utiliser et les différents langages intermédiaires. La Section 3 vous présente l'infrastructure de test qui vous accompagnera pour débugger votre compilateur. Les sections suivantes décrivent le travail que vous aurez à faire lors des séances de TP. Le découpage en TP est donné à titre indicatif. Si vous n'avez pas fini le travail demandé à la fin d'un TP, vous pourrez utiliser un bout de la séance suivante (ou de vos soirées) pour le finir. Essayez de ne pas prendre trop de retard.

Vous trouverez le squelette associé à ce TP à l'adresse suivante :

https://gitlab-research.centralesupelec.fr/cidre-public/compilation/infosec-ecomp

Si vous voulez travailler sur ce projet dans un dépôt git pour partager votre code avec votre binôme, créez un dépôt vierge sur la plateforme de votre choix (un gitlab de CentraleSupélec, un github, autre chose), puis utilisez la procédure suivante :

```
$ git clone https://gitlab-research.centralesupelec.fr/cidre-public/compilation/infosec-ecomp
$ cd infosec-ecomp
$ git remote rename origin le-remote-d-origine
$ git remote add origin git@votre-nouveau-depot.com/.../votre-depot.git
```

Vous pourrez alors utiliser ce dépôt git normalement (commit / push / pull) comme vous avez l'habitude. Peut-être (comprendre  $s\hat{u}rement$ ) que nous modifierons le squelette au cours de ce projet. À ce moment là, nous vous préviendrons et il faudra committer vos changements sur votre propre dépôt git avant de faire :

```
$ git pull le-remote-d-origin master
```

Ce qui récupérera les changements que nous aurons poussés. (La plupart du temps, ce ne sera pas pour vous embêter mais pour vous fournir du code plus robuste et mieux documenté. Il n'est pas exclus qu'on vous donne un jour la solution du TP sans faire exprès et qu'on vous demande de ne pas la regarder.)



# 2 Organisation du compilateur

La figure 1 donne un aperçu de la structure du compilateur que vous allez réaliser. À partir d'un fichier source .e, l'analyseur lexical (ou lexer) générera un flux de lexèmes (ou tokens). Ce flux sera donné à l'analyseur syntaxique (ou parser) qui devra générer un arbre de syntaxe abstraite (Abstract Syntax Tree, ou AST). L'AST sera transformé dans une séquence de langages intermédiaires :

- un programme E, qui simplement une représentation formelle, en OCaml, du programme source;
- un programme CFG (Control-Flow Graph);
- un programme RTL (Register Transfer Language);
- un programme Linear;
- un programme LTL (Location Transfer Language);
- un programme Assembleur RISC-V.

Chacun de ces langages intermédiaire est détaillé ci-dessous, et est illustré sur l'exemple de la Figure 2a.

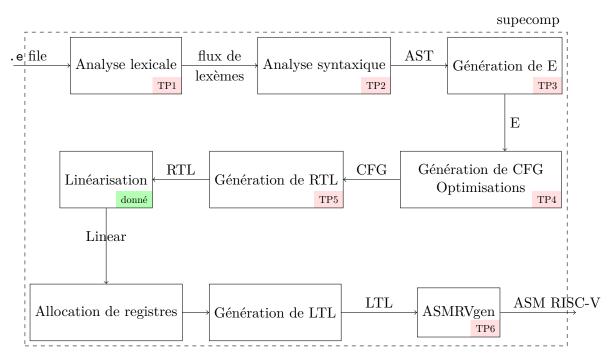


Figure 1 – Aperçu de la structure du compilateur

# 3 Tests

Vous trouverez dans le répertoire tests un ensemble d'outils vous permettant de tester votre compilateur. Les dossiers array, basic, funcall, real\_args, strings et struct contiennent des programmes E vous permettant de tester les fonctionnalités correspondant au nom du dossier. Durant les séances de TP, nous nous concentrerons exclusivement sur les tests du dossier basic.

Lors des séances de projet, vous serez amenés à améliorer votre compilateur pour étendre son langage vers du C. Lors de ces extensions, vous pourrez utiliser les tests fournis dans les différents autres répertoires.

main(a,b){

}

}

while(b != 0){

b = a % b;

(a) Programme E

main:

.global main

sd ra, 0(sp) addi sp, sp, -8

sd s0, 0(sp)

sd s1, 0(sp)

sd s2, 0(sp)

mv s0, sp

main\_2:

li s1, 0

j main\_1 main\_1:

mv a0, a0

j main\_6

addi sp, sp, -8

addi sp, sp, -8

addi sp, sp, -8

addi sp, sp, 0

t = b;

a = t;

return a;

```
main
                               (b != 0)
                                               main(r0, r1):
                                               main_2:
                                  else
                                               r2 <- 0
                                               r1 != r2 ? jmp main_5
                                               jmp main_1
                      t = b
                               return a
                                               main_3:
                                               r0 <- r3
                                               jmp main_2
                                               main_5:
                                               r3 <- r1
                         b = (a \% b)
                                                jmp main_4
                                               main_4:
                                               r4 <- %(r0, r1)
                                               r1 <- r4
                             3
                                               jmp main_3
                                               main_1:
                               a = t
                                               ret r0
                      (b) CFG correspondant
                                                     (c) Programme RTL
                                main_5:
                                mv s2, a1
                                remu s1, a0, a1
                                mv a1, s1
                                mv a0, s2
                                j main_2
                                main_6:
                                mv sp, s0
                                ld s2, 0(sp)
                                addi sp, sp, 8
                                ld s1, 0(sp)
                                addi sp, sp, 8
                                ld s0, 0(sp)
bne a1, s1, main_5
                                addi sp, sp, 8
                                ld ra, 0(sp)
                                addi sp, sp, 8
                                jr ra
```

(d) Assembleur RISC-V

FIGURE 2 – Les différents langages intermédiaires utilisés lors de la compilation d'un programme



Pour chaque fichier test.e, nous vous avons fourni la sortie attendue avec les paramètres 1, 2 et 3 dans test.e.expect\_1\_2\_3 et avec les paramètres 14, 12, 3, 8 et 12 dans test.e.expect\_14\_12\_3\_8\_12. Vous pouvez tester que votre compilateur est conforme à ce qui est attendu en lançant make test depuis la racine de votre projet.

Les résultats des tests seront rassemblés dans le fichier tests/results.html que vous pouvez visualiser avec votre navigateur web préféré. Les résultats sont présentés sous forme de tableaux où les lignes correspondent aux programmes testés et les colonnes les résultats obtenus à différentes étapes de la compilation. Le nom des programmes sont cliquables pour avoir plus d'informations sur le déroulement de leur compilation.

Pour tester les programmes individuellement vous pouvez utiliser le script tests/test.py ou directement le binaire produit (main.native) avec make :

```
# Commandes utiles
$ tests/test.py -f tests/basic/toto.e
$ tests/test.py -f tests/basic/*.e # équivalent à 'make test'
$ tests/test.py --help
$ ./main.native --help
```



# 4 TP1 : Analyseur lexical

Le but de cette séance de TP est de réaliser un analyseur lexical pour le langage E. Cette séance est l'occasion de mettre en œuvre l'algorithme vu en cours pour la réalisation d'un analyseur lexical. On vous rappelle qu'il repose sur l'utilisation d'un automate déterministe à états finis. Afin d'accélérer votre développement nous allons vous fournir une partie du code, et vous proposer une organisation de votre code.

# 4.1 Fonctions utiles de la librairie standard OCaml

La documentation complète est disponible en ligne sur : https://caml.inria.fr/pub/docs/manual-ocaml/libref

```
— List.mem (e: 'a) (l: 'a list): bool
   retourne vrai si e est dans la liste 1
List.fold_left (f: 'a -> 'b -> 'a) (acc: 'a) (1: 'b list): 'a
   applique f à chaque élément de 1 en stockant le résultat dans acc
— List.map (f: 'a -> 'b) (1: 'a list): 'b list
   retourne une liste dans laquelle f a été appliquée à chaque élément de 1.
— List.filter_map (f: 'a -> 'b option) (l: 'a list): 'b list
   Comme List.map. De plus, les éléments pour lesquels f retourne None sont retirés de la liste
   retournée.
— Set les mêmes fonctions existent pour les ensembles Set
— Set.union (s1: Set.t) (s2: Set.t): Set.t
   retourne l'union des ensembles s1 et s2
— Set.add (e: elt) (s: Set.t): Set.t
   ajoute l'élément e à l'ensemble s
— Hashtbl.find_opt (tbl: ('a, 'b) Hashtbl.t) (k: 'a) -> 'b option)
   retourne l'élément associé à la clé k. Si cette clé n'existe pas dans tbl retourne None.
— Hashtbl.find_replace (tbl: ('a, 'b) Hashtbl.t) (k: 'a) (v: 'b) : unit
   associe la valeur v à la clé k dans la table tbl.
```

## 4.2 Tests

Pour compiler et tester votre code il suffit de lancer make test dans le répertoire racine de votre projet. Les résultats des tests sont stockés dans le fichier tests/results.html.

Résultats attendus sur un exemple :



```
# À la fin du TP, results.html:
$ cat tests/basic/just_a_variable_37.e
                                                         SYM IDENTIFIER (main)
main(){
 just_a_variable = 37;
                                                         SYM_LPARENTHESIS
 return just_a_variable;
                                                         SYM_RPARENTHESIS
                                                         SYM_LBRACE
                                                         SYM_IDENTIFIER(just_a_variable)
                                                         SYM_ASSIGN
                                                         SYM_INTEGER(37)
                                                         SYM_SEMICOLON
# Au début du TP dans results.html:
                                                         SYM_RETURN
Lexing error:
                                                         SYM_IDENTIFIER(just_a_variable)
Lexer failed to recognize string starting with
                                                         SYM_SEMICOLON
→ 'main(){
                                                         SYM RBRACE
 just_a_var
                                                         SYM_EOF
```

Lorsque vous appelez make test, votre compilateur est lancé sur 30 fichiers de tests (les fichiers tests/basic/\*.e). Pour le moment, le fichiers tests/results.html indique que tous ces tests échouent à l'analyse lexicale puisque votre analyseur n'est pas encore écrit. Au fur et à mesure des séances de TP, ce fichier vous donnera de plus en plus d'information, notamment le résultat de l'analyse lexicale, syntaxique ainsi que le résultat de l'exécution de chacun des programmes de test à différents niveaux dans la chaîne de compilation. Cela sera un bon moyen de valider la correction de vos passes de compilation.

Vous pouvez aussi lancer le compilateur « à la main », c'est-à-dire sans passer par le make test :

```
$ make
$ ./main.native -f tests/basic/just_a_variable_37.e -show-tokens -
```

pour lancer le compilateur sur le fichier tests/basic/just\_a\_variable\_37.e et afficher les tokens reconnus. (Le « - » à la fin de la ligne de commande indique qu'on souhaite afficher les tokens sur la sortie standard. Si on veut les écrire dans un fichier, on remplacera ce « - » par le nom du fichier.)

## 4.3 Débogage

Pour vous aider à déboguer, les fonctions suivantes sont à votre disposition :

- nfa\_to\_string et dfa\_to\_string transforment des nfa et dfa en chaînes de caractères (string)
- nfa\_to\_dot et dfa\_to\_dot construisent une représentation visuelle d'un dfa dans un fichier \*.dot. Le fichier \*.dot pourra ensuite être transformé en image via la commande \$ dot fichier.dot -Tsvg -o fichier.svg.

Vous trouverez des exemples d'utilisations de ces fonctions dans le fichier src/test\_lexer.ml. Ce fichier contient ce qui s'apparente à une fonction main en C : une déclaration de fonction let () = .... Dans cette fonction, une liste d'expressions régulières est créée, affichée, transformée en NFA. Ce NFA est affiché avec nfa\_to\_string d'une part et nfa\_to\_dot d'autre part, ce qui génère un fichier /tmp/nfa.dot, que vous pouvez convertir en image SVG avec la commande suivante :

```
$ dot -Tsvg /tmp/nfa.dot -o /tmp/nfa.svg
```

Ou bien en utilisant un convertisseur en ligne, ici par exemple : https://dreampuf.github.io/GraphvizOnline. Le NFA est ensuite déterminisé, le DFA résultant est affiché puis écrit dans



/tmp/dfa.dot.

Pour lancer ces tests, il vous suffit de lancer la commande make test\_lexer depuis le répertoire src.

#### 4.4 Travail à effectuer

Le développement de notre analyseur lexical se déroule en trois étapes. Premièrement, la spécification des expressions régulières permettant de reconnaître les termes du langage E. Ensuite, un NFA (Non-deterministic Finite Automaton) pourra être généré pour ces expressions régulières. Finalement, ce NFA sera transformé en DFA (Deterministic Finite Automaton) qui sera utile à l'analyseur pour reconnaître les termes du langage E et les associer au bon lexème. Le travail que vous réaliserez au cours de cette séance se déroulera dans les fichiers src/lexer\_generator.ml et src/e\_regexp.ml.

# 4.4.1 Expressions régulières du langage E

Un premier travail est de donner à l'analyseur différentes expressions régulières permettant d'identifier les mots-clés et noms de variables du langage E. Pour vous familiariser avec le langage E, n'hésitez pas à parcourir le répertoire tests/basic, où une trentaine d'exemples vous sont donnés.

Question 4.1. Compléter la fonction list\_regexp du fichier src/e\_regexp.ml en remplaçant les regex Eps par une expression régulière adéquate. À noter que les variantes regex sont définies plus haut dans le fichier et que la liste de symboles est disponible dans le fichier src/symbols.ml.

# 4.4.2 Expressions régulières en NFAs

Nous souhaitons maintenant produire le NFA correspondant aux expressions régulières utilisées pour analyser le language.

Question 4.2. Écrire les fonctions cat\_nfa, alt\_nfa et star\_nfa du fichier src/lexer\_generator.ml. Ces fonctions permettent respectivement la concaténation, l'union et la répétion d'automates nfa.

Le type nfa est décrit et commenté au début du fichier.

Question 4.3. Compléter la fonction nfa\_of\_regexp qui produit un NFA à partir d'une expression régulière. Les cas Eps et Charset c sont donnés en exemple. Traiter les variantes restantes de regexp.

#### 4.4.3 Déterminisation d'un NFA en DFA

Cette partie se charge de transformer un NFA en DFA en suivant les étapes décrites en cours. Le type dfa utilisé dans cette partie est défini et commenté dans le fichier src/lexer\_generator.ml.



Question 4.4. Compléter les fonctions epsilon\_closure et epsilon\_closure\_set qui retournent les états accessibles par  $\varepsilon$ -transitions d'un état ou d'un ensemble d'états d'un graphe nfa. Plus particulièrement, il faut écrire la fonction récursive traversal pour epsilon\_closure.

Question 4.5. Construire l'expression transitions de la fonction build\_dfa\_table. Cette fonction permet de construire la table de transitions d'un dfa à partir d'un nfa. Les différentes étapes permettant de construire cette table de transitions sont spécifiées dans les commentaires situées au-dessus de la fonction.

Question 4.6. Compléter les fonctions min\_priority et dfa\_final\_states permettant de définir les états finaux de notre dfa. Les états finaux d'un dfa correspondent aux états qui contiennent au moins un état final d'un nfa. La fonction de conversion associée à un état final est obtenue en faisant usage de min\_priority.

Question 4.7. Pour finir la construction de notre DFA, compléter la fonction de transition make\_dfa\_step en utilisant la table de transition construite précédemment avec build\_dfa\_table.

#### 4.4.4 Obtention de lexèmes à l'aide du DFA

Nous avons maintenant obtenu un DFA capable de reconnaître les mots-clés et variables du langage E. Nous souhaitons maintenant que notre DFA décompose les chaînes de caratères d'un programme E en une série de lexèmes/jetons définis dans le fichier src/symbols.ml.

Question 4.8. Complétez la fontion tokenize\_one. Celle-ci contient une fonction récursive recognize qui effectue des transitions dans le DFA tant que possible et retourne un jeton lorsqu'il aboutit.

Note: vous aurez besoin de la fonction string\_of\_char\_list qui transforme un char list en string

Nous vous offrons les dernières étapes, à savoir

- la fonction tokenize\_all qui répète tokenize\_one tant qu'il y a des lexèmes à lire,
- la fonction tokenize\_file qui transforme un nom de fichier en la liste des lexèmes qui sont reconnus dans ce fichier,
- les morceaux de code dans main.ml qui appellent le lexer.

Si tout va bien, un make test maintenant vous affiche plein d'erreurs, mais de syntaxe seulement :-)



# 5 TP2: Analyseur syntaxique

Lors du TP précédent, vous avez écrit un analyseur lexical pour le langage E, et avez donc obtenu, à partir d'un fichier source .e un flux de lexèmes. Le but de ce TP est de construire un analyseur syntaxique. Pour ce faire, vous allez devoir écrire la grammaire du langage E dans un format spécifique et utiliser un générateur d'analyseur syntaxique.

# 5.1 ALPAGA: An LL(1) PArser GenerAtor

Il existe un certain nombre de générateurs d'analyseurs syntaxiques, les plus connus étant yacc (yet another compiler compiler) et bison (qui génèrent du code C), leur cousin ocamlyacc (qui génère du code Ocaml), menhir (qui génère aussi du code Ocaml, mais également du Coq!), ANTLR (ANother Tool for Language Recognition, écrit en Java et qui génère du Java, C‡, python, JavaScript, Go, C++, et du Swift). Tous ces outils acceptent une grammaire en entrée, dans un format particulier, et produisent du code source qui parcourt le flux de lexèmes et produisent un arbre de syntaxe abstraite.

Afin d'avoir un contrôle fin sur le parser généré, et pour pouvoir exporter un certain nombre d'informations utiles lors de l'écriture de la grammaire, nous avons choisi de construire notre propre outil, et ainsi ajouter ALPAGA (An LL(1) PArser GenerAtor) au bestiaire des générateurs de parsers. ALPAGA est écrit en OCaml et produit du code OCaml (une version qui produit du C existe aussi pour vos camarades de la majeure SIS) qui pourra être intégré à votre compilateur.

En plus du code de l'analyseur syntaxique, ALPAGA produit un fichier HTML qui contient un certain nombre d'informations intéressantes. Regardons par exemple la Figure 3, le fichier généré par une toute petite grammaire.

# Grammaire

# Table LL

(1)S	->EXPR SYM_EOF			
(2) EXPR	-> <u>IDENTIFIER</u>			
(3)	-> <u>INTEGER</u>			
(4)	-> EXPR SYM_PLUS EXPR			
(5)	-> EXPR SYM_ASTERISK EXPR			
(6) INTEGER	-> SYM_INTEGER			
(7) IDENTIFIER -> SYM_IDENTIFIER				

(a) La grammaire (cliquable)

# Table First

Non-terminal	First
S	SYM_IDENTIFIER SYM_INTEGER
EXPR	SYM_IDENTIFIER SYM_INTEGER
INTEGER	SYM_INTEGER
IDENTIFIER	SYM_IDENTIFIER

(b) La relation First

	SYM_EOF	SYM_IDENTIFIER	SYM_INTEGER	SUITE	SYM_ASTERISK
S		1	1		
EXPR		<u>2 4 5</u>	<u>3 4 5</u>		
INTEGER			<u>6</u>		
IDENTIFIER		7			

(c) La table LL

FIGURE 3 – Fichier généré pour une petite grammaire d'expressions

On peut donc voir (Figure 3a) la grammaire que l'on a écrite, où chaque règle est numérotée, et chaque non-terminal de la grammaire est un lien vers l'ensemble des règles associées à ce non-

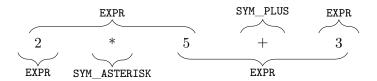


terminal. Cela paraît anecdotique pour cette toute petite grammaire, mais votre grammaire ne tiendra pas sur un seul écran et cette fonctionnalité sera alors très appréciée.

La Figure 3b donne pour chaque non-terminal, l'ensemble des terminaux qui peuvent commencer ce non-terminal. On voit que les non-terminaux S et EXPR acceptent un identifiant ou un entier, comme premier lexème. Des tables similaires existent pour les fonctions Null et Follow, vues en cours.

Finalement, la Figure 3c montre la table de prédiction qui va servir de matrice au parser généré. Chaque ligne correspond à un non-terminal que l'on souhaite parser. S est un nom classique pour désigner la règle de départ d'une grammaire, qu'on appelle l'axiome de la grammaire. Chaque colonne correspond à un terminal (lexème, token, symbole) qui vient du lexer. Si la case (NT, T) est vide, cela signifie que le non terminal NT ne peut pas commencer par le terminal T, autrement dit  $T \notin First(NT)$ . Si la case contient un numéro n, cela signifie qu'il faut appliquer la règle portant ce numéro. Si la case contient plusieurs numéros, il y a un conflit; notre grammaire est ambigüe.

Effectivement, comment doit-on analyser l'expression 2 \* 5 + 3?



Les deux dérivations sont conformes à la grammaire, mais donnent deux résultats différents : (2\*5)+3 d'un côté, qui vaut 13, et 2\*(5+3) de l'autre, qui vaut 16. Bien sûr, vous avez appris à l'école que l'addition est plus prioritaire que la multiplication et que c'est donc la première solution qui est la bonne. Pour expliquer cela à notre grammaire, comme vu en cours, il faut écrire la grammaire autrement, comme dans la figure 4. Dans la table LL (Figure 4c), les numéros de règle en bleu correspondent aux règles qui peuvent être appliqués car le terminal en question peut commencer ce non-terminal  $(t \in First(nt))$ ; les numéros en rouge correspondent aux règles qui peuvent être appliquées lorsque le non-terminal est nullable et que le terminal peut suivre ce non-terminal  $(Null(nt) \land t \in Follow(nt))$ .

Comme on le voit, la grammaire est plus compliquée à écrire, moins naturelle, mais non-ambigüe et la table générée est sans conflits.

#### 5.1.1 Format de la grammaire

Voici le fichier de grammaire donné à ALPAGA pour l'exemple précédent.

tokens SYM\_EOF SYM\_IDENTIFIER<string> SYM\_INTEGER<int> SYM\_PLUS SYM\_ASTERISK non-terminals S EXPR TERM TERMS FACTOR FACTORS INTEGER IDENTIFIER axiom S

rules

S -> EXPR SYM EOF

IDENTIFIER -> SYM\_IDENTIFIER

INTEGER -> SYM\_INTEGER

EXPR -> TERM TERMS

TERM -> FACTOR FACTORS

TERMS -> SYM PLUS TERM TERMS

TERMS ->

FACTOR -> IDENTIFIER



## Grammaire

(1)	S	->EXPR SYM_EOF			
(2)	EXPR	->TERM TERMS			
(3)	TERM	-> FACTOR FACTORS			
(4)	TERMS	-> SYM_PLUS <u>TERM TERMS</u>			
(5)		-> E			
(6)	FACTOR	-> <u>IDENTIFIER</u>			
(7)		-> <u>INTEGER</u>			
(8)	FACTORS	-> SYM_ASTERISK FACTOR FACTORS			
(9)		-> E			
(10)	) INTEGER	-> SYM_INTEGER			
(11)	(11)IDENTIFIER->SYM_IDENTIFIER				

(a) La grammaire (cliquable)

# **Table First**

Non-terminal	First
S	SYM_IDENTIFIER SYM_INTEGER
EXPR	SYM_IDENTIFIER SYM_INTEGER
TERM	SYM_IDENTIFIER SYM_INTEGER
TERMS	SYM_PLUS
FACTOR	SYM_IDENTIFIER SYM_INTEGER
FACTORS	SYM_ASTERISK
INTEGER	SYM_INTEGER
IDENTIFIER	SYM_IDENTIFIER

(b) La relation First

# **Table LL**

	SYM_EOF	SYM_IDENTIFIER	SYM_INTEGER	SYM_PLUS	SYM_ASTERISK
S		1	1		
EXPR		1 2 3	1 2 3		
TERM		<u>3</u>	<u>3</u>		
TERMS	<u>5</u>			4	
FACTOR		<u>6</u>	<u>7</u>		
FACTORS	<u>9</u>			9	8
INTEGER			<u>10</u>		
IDENTIFIER		11			

(c) La table LL

FIGURE 4 – Fichier généré pour une petite grammaire d'expressions

FACTOR -> INTEGER
FACTORS -> SYM\_ASTERISK FACTOR FACTORS
FACTORS ->

Le format du fichier est donc le suivant :

- Déclarations de terminaux (tokens). On déclare les terminaux qui vont être utilisés. Dans notre cas, il s'agira de l'ensemble des symboles (éléments du type symbols du fichier src/symbols.ml) générés au TP précédent. On place le mot clé tokens suivi de la liste des tokens. On peut donner plusieurs telles lignes.
  - À noter que pour les lexèmes non-constants (SYM\_IDENTIFIER et SYM\_INTEGER) on spécifie le type du paramètre entre chevrons : <string> ou <int>.
- Déclarations de non-terminaux. De manière similaire, on déclare la liste des non-terminaux que l'on va reconnaître, les uns à la suite des autres, après le mot-clé non-terminals.
- Déclaration de l'axiome de la grammaire : axiom S
- Le mot-clé rules. Cela délimite les déclarations de terminaux et non-terminaux de la suite du fichier.
- Une suite de règles, composées de :
  - un non-terminal
  - une flèche (->)
  - une suite (éventuellement vide) de terminaux et non-terminaux



Par exemple, la règle TERM -> FACTOR FACTORS signifie que le non-terminal TERM peut être reconnu en reconnaissant d'abord le non-terminal FACTOR, puis le non-terminal FACTORS. Autre exemple, la règle FACTORS -> signifie que le non-terminal FACTORS peut être reconnu par une suite vide de symboles.

# 5.1.2 Options d'ALPAGA

Le programme ALPAGA répond gentiment à l'option --help :

```
$ alpaga/alpaga --help
Usage:
    -g Input grammar file (.g)
    -t Where to output tables (.html)
    -pml Where to output the parser code (.ml)
    -help Display this list of options
    --help Display this list of options
$ alpaga/alpaga -g fichier-grammaire.g -t table.html -pml mon-parser.ml
```

Cela lira le fichier de grammaire fichier-grammaire.g et générera le code du parser dans mon-parser.ml. Une autre sortie du générateur est un fichier table.html. Ce fichier, que vous pouvez ouvrir dans un navigateur web, vous montrera votre grammaire dans un format cliquable, les tables Null, First et Follow nécessaires à la création du parser, et finalement la table LL obtenue. Notamment, les cellules de la table s'afficheront en fond rouge si un conflit a été détecté. Si tel est le cas, il faudra réécrire votre grammaire pour lever les ambiguïtés.

Note : Votre compilateur s'attend à trouver le parser généré dans les fichiers src/generated\_parser.ml. Faites en sorte de ne pas le contrarier. (Ou plutôt : ne lancez pas ALPAGA à la main, le Makefile s'occupera de ça très bien pour vous.)

Le fichier expr\_grammar\_action.g contient un début de grammaire avec une règle qui comporte une action (du code entre accolades). Ignorez ce bout de code pour le moment, on y reviendra dans les questions suivantes.

Question 5.1. Complétez le fichier expr\_grammar\_action.g la grammaire pour le langage E, dans le format attendu par ALPAGA. Votre analyseur devrait consommer les lexèmes mais ne pas produire d'AST (vous n'avez rien fait pour cela encore).

Cet analyseur simple vous permettra de vous assurer que votre grammaire est correcte, indépendamment des actions que vous écrirez par la suite. Ainsi, sur un programme syntaxiquement correct, votre analyseur devrait réussir silencieusement. Pour un programme syntaxiquement incorrect, vous devriez obtenir une erreur de syntaxe.

Votre analyseur devrait réussir sur tous les fichiers .e présents dans le répertoire tests, à l'exception des fichiers syntax\_error\*.e. Plus précisément, la table du fichier tests/results.html devrait contenir une erreur de génération de E, et non plus une erreur de syntaxe.

À ce stade, vous savez donc reconnaître des programmes syntaxiquement valides, mais ne construisez pas d'arbre de syntaxe abstraite. Intéressons-nous maintenant à ce problème.

ALPAGA permet de spécifier, pour chaque règle de la grammaire, une **action**, *i.e.* une expression OCaml qui construit *quelque chose* pour cette règle. Par défaut, lorsqu'aucune action n'est explicitement spécifiée, l'action utilisée est () (la constante de type **unit**). Pour spécifier une action, il suffit d'ajouter à la fin de la ligne correspondant à une règle, du code OCaml entre accolades.

Regardons par exemple la grammaire, avec actions, ci-dessous :



```
tokens SYM_EOF SYM_IDENTIFIER<string> SYM_INTEGER<int> SYM_PLUS SYM_ASTERISK
non-terminals S EXPR TERM FACTOR INTEGER IDENTIFIER
non-terminals TERMS FACTORS
{
  let resolve_associativity term terms = ...
}
rules
S -> EXPR SYM EOF { $1 }
IDENTIFIER -> SYM_IDENTIFIER { StringLeaf($1) }
INTEGER -> SYM_INTEGER { IntLeaf($1) }
EXPR -> TERM TERMS { resolve_associativity $1 $2 }
TERM -> FACTOR FACTORS { resolve_associativity $1 $2 }
TERMS -> SYM_PLUS TERM TERMS { (Tadd, $2) :: $3 }
TERMS -> { [] }
FACTOR -> IDENTIFIER { $1 }
FACTOR -> INTEGER { $1 }
FACTORS -> SYM_ASTERISK FACTOR FACTORS { (Tmul, $2) :: $3 }
FACTORS -> { [] }
```

Quelques remarques sur cette grammaire :

- On a inséré un bloc de code, entre accolades, juste avant la ligne 'rules'. Ce bloc de code sera inséré dans le code du parser généré. On peut donc y définir des fonctions, importer des modules (open Symbols), qui seront utilisables dans les actions de la grammaire.
- Les règles pour les non-terminaux IDENTIFIER et INTEGER construisent des feuilles de l'arbre de syntaxe abstraite. Le type des arbres est défini dans src/ast.ml.
- On peut utiliser dans les actions des variables spéciales 1, 2, ... La variable i correspond à l'objet i renvoyé par le i-ième élément de la règle. Concrètement, dans la règle :

```
TERMS -> SYM_PLUS TERM TERMS { (Tadd, $2) :: $3 }
```


la variable \$2 correspond au résultat renvoyé par TERM et la variable \$3 correspond au résultat renvoyé par TERMS.

- Sur des terminaux, la variable \$i renvoie la chaîne de caractères qui a servi à reconnaître ce terminal. Utilisé notamment pour les terminaux SYM\_IDENTIFIER et SYM\_INTEGER qui sont respectivement de type string et int.
- Dans la règle EXPR -> TERM TERMS { resolve\_associativity \$1 \$2 }, on appelle une fonction sur les éléments produits par les non-terminaux TERM et TERMS. En regardant un peu les autres règles, on comprend qu'un appel à resolve\_associativity pourrait être effectué avec les paramètres :

```
resolve_associativity (IntLeaf(1)) [(Tsub,IntLeaf 2); (Tsub, IntLeaf 3)]
```

ce qui correspond à l'analyse syntaxique de la phrase 1-2-3. Le but de la fonction resolve\_associativity est de construire l'arbre suivant :





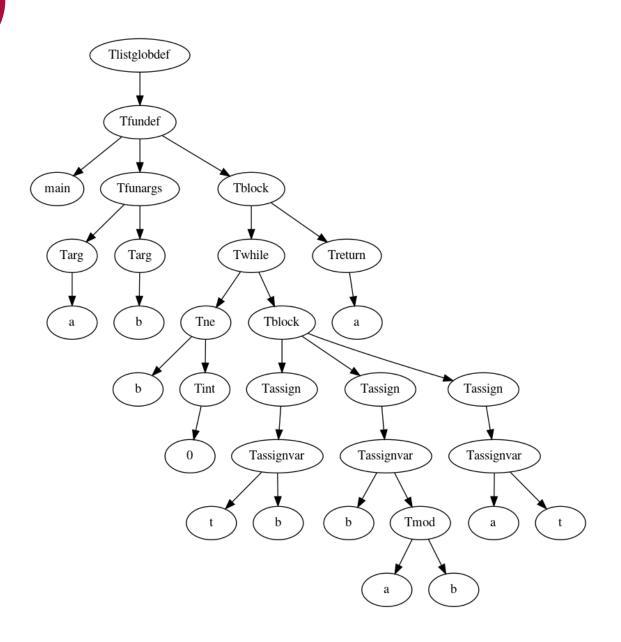
```
Node (Tsub, [
   Node (Tsub, [IntLeaf 1, IntLeaf 2]);
   IntLeaf 3
])
```

Question 5.2 (Action!). Ajouter des actions à votre grammaire afin de construire un AST similaire à celui montré ci-dessus. Référez-vous au fichier src/ast.ml qui document le type des arbres de syntaxe abstraite.

Quand vous aurez écrit les actions, pour tester, relancer make test depuis la racine de votre projet pour que :

- ALPAGA regénère le parseur dans le fichier src/generated\_parser.ml;
- que tout le compilateur soit recompilé (wow!);
- que les tests soient relancés.

Après cela, dans la table de tests/results.html, la page accessible depuis chaque lien correspondant à un nom de fichier devrait contenir un arbre de syntaxe abstraite (une représentation graphique de l'arbre que vous aurez construit). Ce qui devrait ressembler à cela :





# 6 TP3: Génération et interprétation de programmes E

À partir de l'AST, vous allez maintenant devoir générer un programme E, et écrire un interpréteur pour ces programmes. La représentation OCaml des programmes E est définie dans le fichier elang.ml, décrit en cours.

Le fichier elang\_print.ml contient quelques fonctions d'affichage d'expressions, instructions et programmes E. Jetez-y un œil pour déboguer vos programmes.

#### 6.1 Génération de E

L'objectif est de générer un programme E à partir d'un AST. Les fonctions suivantes sont à compléter dans le fichier src/elang\_gen.ml.

Question 6.1. Écrivez la fonction make\_eexpr\_of\_ast (a: tree) : expr res qui transforme un sous-arbre a en une expression E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

Question 6.2. Écrivez la fonction make\_einstr\_of\_ast (a: tree) : instr res qui transforme un sous-arbre a en une instruction E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

Question 6.3. Complétez la fonction make\_fundef\_of\_ast (a: tree) : (string \* efun) res qui transforme un sous-arbre a en une définition de fonction E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

Question 6.4. Complétez la fonction make\_eprog\_of\_ast (a: tree) : eprog res qui transforme un sous-arbre a en un programme E. Cette fonction renvoie une erreur si l'arbre ne répond pas au format attendu.

## 6.2 Interprétation de E

Un moyen de vérifier que votre construction d'AST et transformation en E est correcte, est d'interpréter vos programmes, *i.e.* de les exécuter! Pour cela, vous allez écrire une fonction qui prend un programme E et une liste d'arguments, et qui rend la valeur retournée par ce programme.

Vous allez avoir besoin d'un **état de programme** : une structure de données qui mémorise la valeur de chaque variable tout au long de l'exécution de votre programme. Le fichier prog.ml contient notamment le type 'a state.

```
type 'a state = {
  env: (string, 'a) Hashtbl.t;
  mem: Mem.t
}
```



```
let init_state memsize =
  {
    mem = Mem.init memsize;
    env = Hashtbl.create 17;
}
```

Nous reviendrons sur la composante "mémoire" plus tard, lorsque l'on en aura besoin. Pour le moment, concentrons-nous sur l'environnement. Il s'agit d'une table de hâchage où les clés sont des noms de variables et les valeurs sont de type 'a. Dans un premier temps, on instanciera 'a avec int. Plus tard, on pourra enrichir avec le type des variables.

On utilisera donc les fonctions Hashtbl.replace : ('a, 'b) Hashtbl.t -> 'a -> 'b -> unit et Hashtbl.find\_option : ('a, 'b) Hashtbl.t -> 'a -> 'b option pour écrire et lire dans l'environnement.

Question 6.5 (Passage de paramètres). Dans la fonction eval\_eprog : (oc: formatter) (ep: eprog) (memsize : int) (params: int list) : int option res, construisez l'état initial du programme avec la liste d'arguments passés en paramètres. Notez que la liste ne contient que les valeurs; les noms des paramètres sont dans le programme lui-même (dans f.funargs).

Lancez votre compilateur avec l'option -e-run suivi des paramètres que vous voulez passer, et affichez l'état de votre programme pour vérifier que tout se passe bien.

Note : ignorez les paramètres superflus de la ligne de commande (par exemple, si votre programme attend 2 paramètres et que vous en fournissez 4, ignorez les deux derniers).

Passons maintenant à l'évaluation des expressions!

Question 6.6. Écrivez le corps des fonctions eval\_unop : unop -> int -> int et eval\_binop : binop -> int -> int -> int, qui prennent un opérateur (unaire ou binaire) et leurs paramètres entiers, et renvoient le résultat.

Question 6.7. Écrivez la fonction eval\_eexpr : int state -> expr -> int res qui évalue une expression e, étant donné un état s (de type int state).

Question 6.8. Écrivez la fonction eval\_einstr (oc: formatter) (st: int state) (ins: instr): (int option \* int state) res qui exécute l'instruction i avec l'état s.

Si l'instruction à exécuter contient un return, une valeur de retour peut être retournée : c'est la première composante du résultat (int option).

L'état peut évoluer, notamment lors d'affectations : la seconde composante du résultat (int state) donne le nouvel état.

Finalement, tout ça peut échouer (lecture d'une variable non initialisée), d'où le type res.



Question 6.9. Appelez correctement eval\_einstr dans la fonction eval\_eprog, renvoyez la valeur finale du programme, ou une erreur si aucune valeur n'est renvoyée.



# 7 TP4 : Analyse de vivacité et élimination de code mort

L'objectif de cette séance est de programmer une optimisation pour notre compilateur : l'élimination des affectations mortes. Cette optimisation repose sur une analyse préalable du code du programme, qui sera facilitée par l'utilisation d'un langage intermédiaire approprié : CFG. Le langage CFG, utilise les mêmes expressions que le langage E, et un sous-ensemble des mêmes instructions. Les différences majeures sont les suivantes :

- un programme est un graphe de flot de contrôle (d'où le nom du langage : CFG pour Control Flow Graph);
- les instructions de branchement (IF et WHILE) sont encodées dans la structure du graphe directement.

Le langage CFG est décrit dans le fichier src/cfg.ml.

On y trouve notamment le type des expressions expr. Ce sont les mêmes expressions qu'en E. Cependant, lors des extensions de votre compilateur, les expressions E et les expressions CFG sont susceptibles d'évoluer différemment, c'est pourquoi nous avons préféré dupliquer ce type dès le début.

Une fonction CFG (type cfg\_fun) est composée d'une liste d'arguments (cfgfunargs), d'une table de hâchage des nœuds dont les clés sont les identifiants (entiers) des nœuds et la valeur associée est un cfg\_node, et le point d'entrée d'un CFG est l'identifiant d'un nœud particulier du CFG. Les instructions sur chaque nœud du CFG sont du type cfg\_node:

- Cassign(v,e,s) est une affectation v := e. s est l'identifiant du nœud successeur, *i.e.* à quel nœud doit-on sauter ensuite.
- **Creturn**(e) est un retour de fonction, en renvoyant la valeur de l'expression e. Cette instruction n'a pas de successeur.
- Cprint(e,s) affiche la valeur de l'expression e, puis continue l'exécution au nœud s.
- Ccmp(e, s1, s2) évalue l'expression e. Si sa valeur est vraie (pas zéro), alors l'exécution continue au nœud s1; sinon au nœud s2.
- Cnop s: n'effectue aucune opération, puis saute au nœud s.

Les fonctions succs et preds donnent respectivement les successeurs et les prédécesseurs d'un nœud dans un CFG.

Nous vous fournissons le code pour la passe de transformation qui génère un programme CFG à partir d'un programme E (cfg\_gen.ml), un interpréteur pour le langage CFG (cfg\_run.ml) ainsi qu'un afficheur pour les programmes CFG (cfg\_print.ml).

Vous pouvez utiliser l'afficheur en lançant votre compilateur comme suit :

```
$ ./main.native -f mon-fichier.e -cfg-dump mon-fichier.dot
$ dot mon-fichier.dot -Tpng -o mon-fichier.png
```

Vous pouvez utiliser l'interpréteur comme ceci :

```
$ ./main.native -f mon-fichier.e -cfg-run -- 4 12
```

La sortie du compilateur est un objet JSON qui donne des statistiques sur les différentes passes de compilation ("compstep") et exécutions ("runstep"). Dans notre cas, nous devrions trouver un champ "runstep": "CFG" qui contient un attribut "retval" (la valeur de retour du programme), un attribut "output" (la sortie du programme via la fonction print) et un attribut "error" qui contient les éventuelles erreurs survenues.



Lorsque vous lancez make test, la page HTML générée pour chaque fichier de tests contiendra une représentation graphique du programme CFG.

L'optimisation à laquelle on s'intéresse est l'élimination des affectations mortes. Cette optimisation permet de supprimer du programme les affectations  $\mathbf{v}:=\mathbf{e}$  telles que la valeur de  $\mathbf{v}$  n'est jamais lue après cette affectation. Il est aisé de comprendre que dans ce cas, cette affectation peut être supprimée sans modifier le comportement du programme.  $^1$ 

Pour déterminer quelles affectations peuvent être éliminées, nous allons procéder à une analyse de vivacité des variables.

## 7.1 Analyse de vivacité

Cette partie se passe dans le fichier cfg\_liveness.ml. Le but de cette analyse est d'obtenir, pour chaque nœud du programme, l'ensemble des variables qui sont *vivantes* avant et après ce nœud. Il nous suffit en fait de calculer l'ensemble des variables vivantes avant chaque nœud; on pourra calculer, au besoin, à partir de cela les variables vivantes après chaque nœud.

Pour stocker l'ensemble des variables vivantes avant chaque nœud, on utilisera une table de hâchage indexée par des entiers (les identifiants des nœuds du CFG) : (int, string Set.t) Hashtbl.t.

L'analyse se déroulera en calculant le point fixe des équations de flot de données vues en cours, jusqu'à ce qu'une solution stable soit trouvée (*i.e.* jusqu'à ce qu'on n'ajoute plus de variable vivante à aucun point de programme).

Chaque itération de l'analyse mettra à jour l'état de l'analyse, *i.e.* le mapping entre les identifiant de nœuds et la liste des variables vivantes avant ce nœud. Pour chaque nœud, on commencera par calculer l'ensemble des variables vivantes après ce nœud : il s'agit de l'union des variables vivantes avant chacun de ces successeurs. À partir de cet ensemble, on calculera l'ensemble des variables vivantes avant ce nœud : les variables lues deviennent vivantes et les variables écrites deviennent mortes.

Question 7.1. Écrivez une fonction vars\_in\_expr : expr -> string Set.t qui renvoie l'ensemble des variables utilisées par une expression.

Nous vous fournissons, dans le fichier cfg.ml, les fonctions succs : (int, cfg\_node) Hashtbl.t -> int -> int Set.t et preds : (int, cfg\_node) Hashtbl.t -> int -> int Set.t qui renvoient respectivement les successeurs et prédécesseurs d'un nœud dans un CFG.

Question 7.2. Écrivez une fonction live\_after\_node : (int, cfg\_node) Hashtbl.t -> int -> (int, string Set.t) Hashtbl.t -> string Set.t. Plus précisément, life\_after\_node cfg n lives calcule l'ensemble des variables vivantes après exécution du nœud n dans le graphe cfg, étant donné l'ensemble des variables vivantes avant chaque nœud donné par la table lives.

```
Question 7.3. Écrivez une fonction live_cfg_node : cfg_node -> string Set.t -> string Set.t. Par exemple, live_cfg_node node live_after doit renvoyer l'ensemble des
```

<sup>1.</sup> Attention, dans des langages plus riches que le langage E, comme C par exemple, cela n'est valable que si l'expression  ${\bf e}$  n'a pas d'effets de bord.



variables vivantes avant le nœud n, où liv\_after est l'ensemble des variables vivantes après ce nœud.

Question 7.4. Utilisez les fonctions précédentes pour écrire une fonction live\_cfg\_nodes (cfg: (int, cfg\_node) Hashtbl.t) (lives : (int, string Set.t) Hashtbl.t) : bool qui effectue une itération du calcul de point fixe sur le CFG cfg en partant de l'état lives.

Cette fonction met à jour la table lives et renvoie un booléen qui indique si des changements ont eu lieu sur au moins un nœud.

La fonction live\_cfg\_fun : cfg\_fun -> (int, string Set.t) Hashtbl.t est écrite pour vous. Elle calcule l'ensemble des variables vivantes avant chaque nœud du CFG correspondant à une fonction donnée.

# 7.2 Élimination de code mort

Cette partie se passe dans le fichier cfg\_dead\_assign.ml. Nous allons maintenant utiliser le résultat de notre analyse pour optimiser notre programme. Nous allons parcourir le graphe de flot de contrôle et pour chaque nœud correspondant à une affectation (Cassign), si la variable affectée n'est pas vivante après l'affectation, nous allons supprimer cette affectation (plus précisément transformer le nœud en un nouveau nœud de type Cnop).

Question 7.5. Écrire une fonction dead\_assign\_elimination\_fun (f: cfg\_fun) : cfg\_fun qui, étant donnée une fonction de CFG, calcule la vivacité des variables et élimine les affectations mortes.

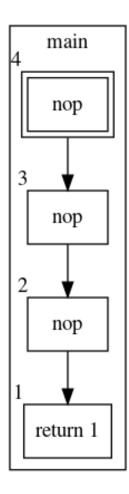
Dans certains cas, le programme transformé peut encore être simplifié par l'application de cette même transformation. En effet, certaines variables pouvaient être vivantes seulement parce qu'elles étaient utilisées dans une affectation concernant une variable elle-même morte. C'est le cas par exemple de l'exemple useless\_assigns.e présent dans votre répertoire tests.

Question 7.6. Modifiez votre code pour appliquer la transformation autant que nécessaire.

## 7.3 Bonus : élimination de NOPs

Dans la section précédente, on a transformé certains nœuds en Cnop, c'est-à-dire no op ou no operation. On s'intéresse maintenant à éliminer ces NOPs.





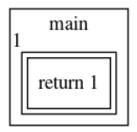
Par exemple, le CFG pour le programme tests/basic/useless-assigns.e ressemblera au CFG ci-contre.

Un certain nombre de fonctions à compléter sont présentes dans le fichier src/cfg\_nop\_elim.ml.

Sur l'exemple ci-contre :

```
- nop_transitions cfg = [(4,3); (3,2); (2,1)]
- follow 4 _ _ = 1
- follow 3 _ _ = 1
- follow 2 _ _ = 1
- follow 1 _ _ = 1
- nop_transitions_closed cfg = [(4,1); (3,1); (2,1); (1;1)]
```

Après application de l'optimisation, le CFG devrait ressembler à :





# 8 TP5 : Génération de programmes RTL

L'objectif de cette séance de TP est de générer des programmes RTL (Register Transfer Language). Comme expliqué dans la section 2, RTL est un language dans lequel le programme est un graphe de flot de contrôle, comme en CFG, mais où les expressions, contrairement à CFG, sont décomposées en opérations élémentaires sur des registres. Il n'y a pas de limites au nombre de registres qu'un programme RTL utilise. En RTL, on perd la notion de variable : toutes les données sont dans des (pseudo-)registres.

Pourquoi choisit-on un tel langage intermédiaire? Ce langage intermédiaire permet de se rapprocher de l'assembleur qui sera généré in fine, on dit qu'il est plus bas niveau que les langages précédents. C'est un choix courant dans des compilateurs connus : le compilateur GCC utilise un langage qui s'appelle aussi RTL et qui partage un certain nombre de caractéristiques avec notre langage RTL, la représentation intermédiare IR de Clang y ressemble aussi, et CompCert utilise également un langage RTL.

La description du langage RTL se trouve dans le fichier src/rtl.ml. On y trouve notamment le type des registres reg (qui est un synonyme pour int).

Les instructions RTL (type rtl\_instr) sont :

- Opération binaire RBinop(b, rd, rs1, rs2) : on effectue l'opération binaire b sur les registres source rs1 et rs2, et on stocke le résultat dans le registre destination rd.
- Opération unaire **RUnop**(u, rd, rs): on effectue l'opération unaire u sur le registre source rs, et on stocke le résultat dans le registre destination rd.
- Opération Rconst(r, i) : on stocke la constante i dans le registre r.
- Opération Rmov(rd, rs) : on copie la valeur contenue dans le registre source rs dans le registre destination rd.
- Opération « label » **Rlabel 1**: on définit un *label* à cet endroit du code. On pourra y sauter par la suite, mais cette opération ne fait rien.
- Opération de branchement Rbranch(cmp, rs1, rs2, 1): on évalue la comparaison cmp (de type rtl\_cmp défini plus haut) sur les registres rs1 et rs2. Si la comparaison s'évalue en vrai (pas zéro), on saute au label 1; sinon on continue l'évaluation normalement.
- Opération de saut inconditionnel Rjmp 1: on saute au label 1.
- Opération Rprint r : affichage du contenu du registre r.
- Opération **Rret** r : on retourne la valeur contenue dans le registre r, et on arrête l'exécution de la fonction courante.

## 8.1 Génération de programmes RTL

Voici le plan d'attaque pour la transformation de programmes CFG en programmes RTL.

- 1. Tout d'abord, il nous faut un moyen de générer des nouveaux noms de registres. Les fonctions que nous allons écrire prendront donc en paramètre un couple (next\_reg, var2reg), où :
  - next\_reg est le numéro du prochain registre disponible (pas encore alloué à une variable, ou utilisé comme registre intermédiaire);
  - var2reg : (string \* int) list est une liste d'association qui contient une paire (v,
     r) si le registre RTL r est associé à la variable CFG dont le nom est v.
- 2. Equipés de ces paramètres, il nous faudra transformer les expressions et instructions CFG en opérations RTL.



Le travail à effectuer se trouve dans le fichier src/rtl\_gen.ml.

La fonction find\_var (next\_reg, var2reg) v, écrite pour vous, renvoie un triplet (r, next\_reg', var2reg') où r correspond au registre correspondant à la variable v, et next\_reg' et var2reg' sont les paramètres d'entrée mis à jour.

Passons maintenant à la compilation des expressions. La compilation d'une expression CFG va produire une liste d'opérations RTL qui vont avoir pour effet de calculer l'expression en question et de stocker sa valeur dans un registre. La fonction rtl\_instrs\_of\_cfg\_expr (next\_reg, var2reg) e effectue cette transformation et doit renvoyer un quadruplet (r, l, next\_reg', var2reg') tel que :

- le résultat de l'expression CFG e est stocké dans le registre r;
- la liste d'instructions RTL correspondant au calcul de ce résultat est 1;
- next\_reg' est var2reg' sont les variables next\_reg et var2reg passées en paramètre, éventuellement mises à jour.

Par exemple, pour compiler l'expression a + 2 \* b, en supposant que next\_reg vaut 0 et var2reg est initialement vide :

— on commence par compiler la sous-expression a. On va donc appeler la fonction find\_var qui nous renverra un triplet (0, 1, [("a", 0)]).

Le résultat de la compilation de cette première sous-expression donnera le quadruplet (0, [], 1, [("a", 0)]). (Aucune opération n'est requise.)

— on compile ensuite la sous-expression 2 \* b.

Tout d'abord, la compilation de la sous-expression 2 nous renverra le quadruplet :

```
(1, [Rconst(1, 2)], 2, [("a", 0)]).
```

Puis, la compilation de la sous-expression b nous renverra le quadruplet :

```
(2, [], 3, [("a", 0); ("b", 2)]).
```

Finalement, on obtiendra pour la sous-expression 2 \* b:

```
(3, [Rconst(1,2); Rbinop(Emul, 3, 1, 2)], 4, [("a", 0); ("b", 2)]).
```

— On combine ces deux sous-résultats : il nous faut un nouveau registre pour stocker le résultat de l'expression en entier :

```
(4, [Rconst(1,2); Rbinop(Emul, 3, 1, 2); Rbinop(Eadd, 4, 1, 3)], 5, [("a", 0); ("b", 2)])
```

```
Question 8.1. Écrivez la fonction rtl_instrs_of_cfg_expr (next_reg, var2reg) e.
```

Les expressions sont maintenant compilées, passons aux nœuds du CFG. Ceux-ci sont transformés en des nœuds RTL, qui partageront le même identifiant. Seulement, au lieu de contenir une « instruction » CFG, ils contiendront une liste d'opérations RTL.

Question 8.2. Écrivez la fonction rtl\_instrs\_of\_cfg\_node (next\_reg, var2reg) (c: cfg\_node) qui renvoie, étant donné un nœud CFG, un triplet (1, next\_reg', var2reg') où 1 est la liste des opérations RTL correspondant à un nœud CFG c et next\_reg' et var2reg' ont le même sens que précédemment.

Vous noterez la présence de la fonction rtl\_cmp\_of\_cfg\_expr : nous vous laissons inter-



préter ce qu'elle fait et comment l'utiliser... Sans doute pour les opérations de branchement?

La fonction suivante, rtl\_instrs\_of\_cfg\_fun, est écrite entièrement pour vous et ne fait qu'utiliser les fonctions précédentes pour construire une fonction RTL. Jetez-y un œil pour comprendre ce qui s'y passe.

Vous avez désormais des programmes RTL!

Un afficheur et un interpréteur de RTL vous sont fournis, à utiliser comme ci-dessous :

```
$ ./main.native -f tests/basic/gcd.e -rtl -
main(r0, r1):
main 2:
r2 <- 0
r1 != r2 ? jmp main_5
jmp main_1
main_3:
r0 <- r3
jmp main_2
main_5:
r3 <- r1
jmp main_4
main_4:
r4 <- %(r0, r1)
r1 <- r4
jmp main_3
main 1:
ret r0
$ ./main.native -f tests/basic/gcd.e -rtl-run -- 21 14
  { "compstep": "Lexing", "error": null, "data": [] },
  { "compstep": "Parsing", "error": null, "data": [] },
  { "runstep": "RTL", "retval": 7, "output": "", "error": null },
# ...
1
```

# 8.2 Linéarisation des programmes RTL

Les programmes RTL sont des graphes de flot de contrôle. La phase suivante est la linéarisation des programmes, c'est-à-dire transformer le graphe en un programme du langage Linear (définis dans le fichier src/linear.ml), qui ne sont qu'une liste d'instructions RTL, incluant des sauts explicites.

Une linéarisation naïve est implémentée dans le fichier src/linear\_gen.ml. Cette linéarisation est naïve car les différents *blocs* d'instructions RTL sont mis les uns à la suite des autres sans considération du graphe de flot de contrôle, et donc sans doute que trop de sauts sont utilisés.

Vous avez donc une linéarisation qui fonctionne, mais qui pourrait être améliorée. Voici comment :

- on pourrait ordonner les nœuds du graphe de flot de contrôle original selon un ordre topologique, c'est-à-dire un parcours en profondeur du graphe.
- si deux blocs d'instructions sont ordonnées l'un juste après l'autre, on peut éviter un saut. Autrement dit, on n'a pas besoin de la suite d'instructions [Rjmp 1; Rlabel 1] (sauter à l'instruction suivante).



— après la transformation précédente, on peut éliminer les labels auxquels aucune instruction ne saute.

Cette section étant optionelle, peu de détails sont fournis et il vous appartient d'explorer comment mettre en place les différentes optimisations présentées ci-dessus.



# 9 TP6: Allocation de registres

Le but de cette séance de travaux pratiques est de réaliser l'allocation de registre, qui permettra de produire du code assembleur qui pourra être assemblé et exécuté par un processeur RISC-V.

L'allocation de registres consiste à spécifier, pour chaque pseudo-registre RTL (ou Linear), à quel emplacement matériel on va le stocker. Concrètement, on associe à chaque pseudo-registre RTL soit un registre matériel, soit un emplacement sur la pile.

Nous vous fournissons un « allocateur de registre » très simple qui alloue tous les pseudo-registres RTL sur la pile et n'utilise donc aucun registre matériel. C'est assurément inefficace puisque cela va générer un grand nombre de lectures/écritures dans la mémoire, mais ça a le mérite de fonctionner.

Vous avez donc déjà un compilateur qui génère des programmes RISC-V exécutables!

```
$ ./main.native -f tests/basic/gcd.e
  { "compstep": "Lexing", "error": null, "data": [] },
  { "compstep": "Parsing", "error": null, "data": [] },
  { "compstep": "CFG", "error": null, "data": [ { "main": 14 } ] },
  { "compstep": "CFG loops", "error": null, "data": [ { "main": 15 } ] },
  { "compstep": "Constprop", "error": null, "data": [ { "main": 15 } ] },
  { "compstep": "DeadAssign", "error": null, "data": [ { "main": 15 } ] },
  { "compstep": "NopElim", "error": null, "data": [ { "main": 14 } ] },
  { "compstep": "DSE", "error": null, "data": [] }
$ tests/basic/gcd.exe 54 24
$ $ ./main.native -f tests/basic/prime.e
 { "compstep": "Lexing", "error": null, "data": [] },
  { "compstep": "Parsing", "error": null, "data": [] },
 { "compstep": "CFG", "error": null, "data": [ { "main": 46 } ] },
 { "compstep": "CFG loops", "error": null, "data": [ { "main": 48 } ] },
 { "compstep": "Constprop", "error": null, "data": [ { "main": 48 } ] },
 { "compstep": "DeadAssign", "error": null, "data": [ { "main": 48 } ] },
   "compstep": "NopElim", "error": null, "data": [ { "main": 46 } ] },
  { "compstep": "DSE", "error": null, "data": [] }
$ tests/basic/prime.exe 54
54
2
3
3
3
0
```

On sait calculer le PGCD de deux entiers et décomposer un entier en facteurs premiers!

De plus, le fichier HTML généré pour chacun des fichiers source (par exemple tests/basic/gcd.e.html) contient, dans la section LTL, l'allocation de chaque pseudo-registre RTL. Par exemple, pour le test tests/basic/gcd.e, on a l'allocation suivante :

```
// In function main
// LinReg 1 allocated to a1
// LinReg 0 allocated to a0
```



```
// LinReg 4 allocated to stk(-32)
// LinReg 3 allocated to stk(-24)
// LinReg 2 allocated to stk(-16)
```

Vous remarquerez que certains pseudo-registres (1 et 0) sont alloués dans des vrais registres machine (a1 et a0) tandis que les autres (2, 3 et 4) sont alloués sur la pile, aux emplacements -16, -24 et -32.

L'objectif de la suite de cette séance est donc d'écrire un allocateur de registres plus intelligent, qui utilisera mieux les registres disponibles en RISC-V.

#### 9.1 Crash course: assembleur RISC-V

RISC-V est une architecture de jeu d'instruction (ISA) ouverte et libre. C'est une architecture de type RISC (Reduced Instruction Set Computer) avec relativement peu d'instructions et un plus grand nombre de registres (comparé à x86 par exemple qui est de type CISC (Complex Instruction Set Computer) et qui a énormément d'instructions et peu de registres). Nous allons présenter ici un sous-ensemble des instructions RISC-V – celles dont on a besoin pour écrire notre compilateur. À noter que nous vous fournissons le code pour la génération de l'assembleur RISC-V (dans src/riscv.ml). Les descriptions qui suivent vous serviront donc pour votre culture, ainsi que pour comprendre le code qui vous est fourni lorsque vous devrez l'étendre.

# 9.1.1 Registres RISC-V

RISC-V existe en 32 bits ou 64 bits (et même 128 bits). Nous allons écrire du code pour RISC-V 32 et 64. Rassurez-vous, la plupart du code peut se factoriser aisément. Dans cette architecture, RISC-V donne accès à 32 registres de 32 ou 64 bits chacun (selon l'architecture), dont voici la liste :

Numéro	Nom	Commentaire	Numéro	Nom	Commentaire	
x0	zero	vaut toujours zéro	x16	a6	arguments	
x1	ra	adresse de retour	x17	a7	arguments	
x2	$\operatorname{sp}$	pointeur de pile	x18	s2		
x3	gp	global pointer	x19	s3		
x4	tp	thread pointer	x20	s4		
x5	t0		x21	s5		
x6	t1	temporaires	x22	s6	registres callee-save	
x7	t2		x23	s7	registres carree-save	
x8	s0/fp	frame pointer	x24	s8		
x9	s1	registre callee-save	x25	s9		
x10	a0	argument / valeur de retour	x26	s10		
x11	a1		x27	s11		
x12	a2		x28	t3		
x13	a3	arguments	x29	t4	temporaires	
x14	a4		x30	t5	temporanes	
x15	a5		x31	t6		

Le registre zero contient toujours la valeur 0.

Le registre ra est utilisé pour stocker l'adresse de retour lors d'un appel de fonction. <sup>2</sup>

<sup>2.</sup> Notons que ce n'est qu'une convention et que l'on pourrait stocker l'adresse de retour dans n'importe quel registre.



Le registre sp contient le pointeur de pile (similaire à esp en x86).

Le registre gp est le *global pointer*. Il contient l'adresse de la zone de mémoire où sont stockées les variables globales. Nous ne l'utiliserons pas dans notre compilateur.

Le registre tp est le *thread pointer*. Il contient l'adresse de la zone de mémoire propre au thread courant. Nous ne l'utiliserons pas dans notre compilateur.

Les registres t0 à t6 sont des registres temporaires qui n'ont pas de vocation particulière.

Le registre s0, aussi appelé fp pour *frame pointer*, contient l'adresse du début de la trame de pile de la fonction courante. C'est l'analogue du registre ebp en x86.

Les registres \$1 à \$11 sont des registres temporaires sans vocation particulière.

Les registres a0 à a7 sont utilisés pour passer les arguments lors d'un appel de fonction (premier argument dans a0, second dans a1...). De plus, la valeur de retour des fonctions est passée dans le registre a0.

Registres caller- et callee-save. Les registres ra, t0-t6 et a0-a7 sont *caller-save*, c'est-à-dire que c'est la responsabilité de la fonction appelante (le *caller*) de sauvegarder ces registres avant de faire un appel de fonction si leur valeur est importante.

Les registres sp, s0-s11 sont callee-save, c'est-à-dire que c'est la responsabilité de la fonction appelée (le callee) de sauvegarder ces registres si la fonction appelée les modifie. On peut donc faire l'hypothèse, lorsqu'on appelle une fonction, que la valeur de ces registres sera la même après l'appel.

#### 9.1.2 Instructions.

Contrairement à x86, où les instructions acceptent plusieurs modes d'adressage pour les opérandes (registres, valeurs immédiates, emplacements mémoire), les instructions RISC-V ont en général un unique mode d'adressage.

La plupart des instructions sont de type « 3 adresses » et attendent des registres comme opérandes. Deux schémas principaux émergent :

- op rd, rs1, rs2 où op est une opération (add, mul, div, remu (pour remainder unsigned, a.k.a. modulo)...), rd est le registre de destination, et rs1 et rs2 sont les registres source.
- op rd, rs où op est une opération (neg, ...), rd est le registre de destination, et rs est le registre source.

Pour compiler les conditionnelles (par exemple  $r1 \leftarrow r2 \leftarrow r3$ ), on a besoin des instructions supplémentaires suivantes :

```
— slt rd, rs1, rs2: rd vaut 1 \text{ si rs1} < \text{rs2}, 0 \text{ sinon}
```

- segz rd, rs : rd vaut 1 si rs vaut zéro, 0 sinon
- snez rd, rs:rd vaut 0 si rs vaut zéro, 1 sinon

## Les instructions de branchement.

- Saut inconditionnel: j <label>
- Appel de fonction : jal ra, <label>
- Saut si deux registres sont égaux : beq rs1, rs2, <label>
- Saut si rs1 < rs2 (en unsigned ou pas): blt[u] rs1, rs2, <label>
- Saut si rs1 >= rs2 (en unsigned ou pas): bge[u] rs1, rs2, <label>
- Saut si rs != 0 : bnez rs, <label>



#### Accès à la mémoire

- Lire depuis la mémoire vers un registre : ld rd, ofs(rs). Cette instruction lit la mémoire à l'adresse rs + ofs et stocke le résultat dans le registre rd.
  - ld veut dire *load double-word*, i.e. 64 bits. Pour ne lire que 32 bits, on aurait utilisé lw pour *load word*; pour 16 bits lh pour *load half-word* et pour 8 bits lb pour *load byte*.
- Écrire la valeur d'un registre dans la mémoire : sd rs, ofs(rd). Cette instruction écrit la valeur du registre rs dans la mémoire à l'adresse rd + ofs.
  - sd veut dire *store double-word*, i.e. 64 bits. Pour n'écrire que 32 bits, on aurait utilisé sw pour *store word*; pour 16 bits sh pour *store half-word* et pour 8 bits sb pour *store byte*.

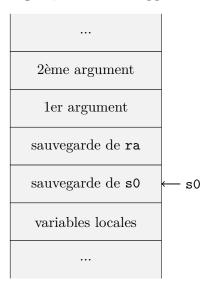
Valeurs immédiates Pour écrire une constante dans un registre : li rd, imm, où rd est le registre de destination et imm est la constante que l'on souhaite stocker.

#### 9.1.3 Code fourni

Nous vous fournissons un allocateur de registres « naïf », dans le fichier src/regalloc.ml. Plus précisément, l'allocateur de registres regalloc\_on\_stack\_fun prend en entrée une fonction linear\_fun et renvoie un couple ((reg, loc) Hashtbl.t \* int). Le premier élément du couple est une table de hachage qui associe à chaque pseudo-registre un emplacement (location en anglais) de type loc définie comme suit :

```
type loc = Reg of int | Stk of int
```

Un emplacement est donc soit un registre physique du processeur cible (ici le processeur RISC-V), soit un slot sur la pile. Un tel slot est un décalage par rapport au registre fp (frame pointer ou cadre de pile). Notez que puisque sur RISC-V (comme sur x86 d'ailleurs) le sommet de pile (le registre sp) décroît vers des adresses plus petites lorsque l'on empile des données sur celle-ci, le décalage entre une variable locale évincée sur la pile et le registre de cadre de pile fp est toujours un entier négatif, comme cela apparaît sur la figure :



L'allocateur fourni fonctionne de manière très simple en parcourant l'ensemble des instructions d'une fonction en langage Linear afin de déterminer les pseudo-registres qu'elle utilise. Pour cela, on fait appel aux fonctions gen\_live et kill\_live qui vous sont fournies dans le fichier



src/linear\_liveness.ml dont le but est précisément de calculer la vivacité des pseudo-registres en langage Linear. On ne vous demande pas de coder de nouveau cette analyse de vivacité puisqu'elle a déjà fait l'objet d'un TP. En faisant l'union de tous les pseudo-registres utilisés par une fonction, il reste plus qu'à itérer sur la liste de ces registres pour allouer à chacun un slot (un entier négatif) qui décroît de 1 pour chacun d'eux (puisque pour le moment toutes les variables sont de type entier de longueur égale à celle de l'architecture sous-jacente).

## 9.2 Allocation de registres

Bien qu'on ait à présent un compilateur complet (dans le sens où on génère des fichiers exécutables), on peut apporter un grand nombre d'améliorations à notre compilateur. Dans cette partie, nous allons écrire un allocateur de registres afin de profiter de la multitude de registres disponibles en RISC-V; et minimiser le nombre d'instructions qui accèdent à la mémoire.

Nous allons écrire un algorithme basé sur la coloration de graphes, comme vu en cours. Pour cela il est nécessaire de procéder au préalable à une analyse de vivacité des pseudo-registres utilisés dans le langage Linear. Comme expliqué plus tôt, cette analyse vous est fournie (fichier src/linear liveness.ml.

Lorsque vous lancez un test sur un exemple, vous pouvez consulter le résultat de cette phase d'analyse de vivacité dans le fichier .linear associé au code compilé :

```
$ ./test.py -f basic/gcd.e
1 threads running (['basic/gcd.e']).
All threads terminated!
1/1 OK.
0/1 KO : []
$ cat basic/gcd.linear
main(r0, r1):
// Live before : { 0, 1 }
main 2:
// Live after : { 0, 1 }
// Live before : { 0, 1 }
// Live after : { 0, 1, 2 }
// Live before : { 0, 1, 2 }
r1 != r2 ? jmp main_5
// Live after : { 0, 1 }
// Live before : { 0 }
jmp main_1
// Live after : { 0 }
// Live before : { 0, 1 }
main 5:
// Live after : { 0, 1 }
// Live before : { 0, 1 }
r3 <- r1
// Live after : { 0, 1, 3 }
// Live before : { 0, 1, 3 }
r4 <- %(r0, r1)
// Live after : { 3, 4 }
// Live before : { 3, 4 }
r1 <- r4
// Live after : { 1, 3 }
// Live before : { 1, 3 }
r0 <- r3
// Live after : { 0, 1 }
```



```
// Live before : { 0, 1 }
jmp main_2
// Live after : { 0, 1 }
// Live before : { 0 }
main_1:
// Live after : { 0 }
// Live before : { 0 }
ret r0
// Live after : { }
```

À partir de cette analyse, nous allons construire un graphe d'interférences : les sommets sont les différents pseudo-registres utilisés dans le programme et on a une arête entre deux pseudo-registres si ceux-ci sont vivants en même temps. Intuitivement, deux pseudo-registres vivants en même temps ne pourront pas être associés au même registre machine. Le problème d'allocation de registre devient alors un problème de coloration de graphes : on souhaite associer une couleur à chaque sommet de sorte que deux sommets voisins dans le graphe sont associés à des couleurs différentes.

# 9.2.1 Allocation de registres par coloration de graphes

Passons maintenant à la construction du graphe d'interférence et à sa coloration. Cela se passe dans le fichier src/regalloc.c.

Construction du graphe d'interférence. La construction du graphe d'interférence sera effectuée par la fonction build\_interference\_graph (live\_out : (int, reg Set.t) Hashtbl.t) : (reg, reg Set.t) Hashtbl.t qui renvoie le graphe d'interférence à partir d'une analyse de vivacité. L'analyse de vivacité est passée sous la forme d'une table de hachage qui associe à chaque instruction du code en langage Linear (identifiée par un entier : sa position dans le programme) un ensemble de registres vivants à la sortie de cette instruction. Cette fonction retourne un graphe d'interférence sous la forme d'une table de hachage qui associe un arc (dirigé) entre chaque registre et les registres avec lequel ce registre est en interférence et donc adjacent dans le graphe.

C'est à vous de construire le graphe, à partir du résultat de vivacité. Vous devez ajouter des arêtes entre deux sommets si à au moins un point de programme, les pseudo-registres associés à ces deux sommets sont vivants en même temps.

```
Question 9.1. Écrivez une fonction add_interf (rig : (reg, reg Set.t) Hashtbl.t) (x: reg) (y: reg) : unit qui met à jour le graphe d'interférence rig (pour register interference graph) en ajoutant un lien entre les sommets x et y.
```

Attention, étant donnée la représentation que l'on a choisi pour le graphe (sous forme de listes d'adjacence), ajouter une arête implique d'ajouter  ${\tt x}$  aux voisins de  ${\tt y}$  et  ${\tt y}$  aux voisins de  ${\tt x}$ .

```
Question 9.2. Écrivez une fonction make_interf_live (rig: (reg, reg Set.t) Hashtbl.t) (live: (int, reg Set.t) Hashtbl.t): unit qui construit le graphe d'interférence.
```

On vous fournit la fonction build\_interference\_graph (live\_out : (int, reg Set.t) Hashtbl.t) : (reg, reg Set.t) Hashtbl.t qui s'assure d'initialiser correctement le graphe



d'interférences avec autant de sommets qu'il y a de pseudo-registres utilisé dans le programme Linear. Cette fonction utilise les fonctions que vous avez définies précédemment.

Coloration du graphe L'algorithme d'allocation de registres par coloration de graphes a été initialement proposé dans un article de recherche par Chaitin et al. en 1981<sup>3</sup>.

On suppose que l'on dispose de N couleurs (registres machine). L'algorithme se déroule en plusieurs phases :

1. On commence par construire une pile de pseudo-registres en indiquant pour chacun si on va être capable d'y associer une couleur (un registre machine) à coup sûr, ou non (dans ce cas, il devra être alloué sur la pile – on dit qu'il est évincé ou *spilled*).

La construction de cette pile s'effectue comme suit :

Tant que le graphe rig n'est pas vide :

- on essaie de trouver un sommet avec strictement moins de N voisins dans rig
  - Si un tel sommet r existe, retirons-le du graphe rig et ajoutons ce registre au sommet de la pile en indiquant qu'on saura lui associer une couleur. Dans notre code on met sur la pile NoSpill r.
  - Sinon, on va devoir évincer (spiller) un pseudo-registre, c'est-à-dire choisir un pseudo-registre qui sera alloué sur la pile. On peut choisir n'importe quel sommet, mais une heuristique particulière consiste à choisir le sommet qui a le plus de voisins : cela aura pour effet de diminuer le nombre de voisins de beaucoup d'autres registres et de permettre de trouver plus facilement par la suite un sommet avec moins de N voisins. On retire ce sommet du graphe, et on l'ajoute au sommet de la pile en indiquant qu'il sera évincé. Dans notre code on met sur la pile Spill r.
- 2. Une fois cette pile construite, on va effectivement associer des couleurs à chaque sommet marqué NoSpill et des emplacements sur la pile à chaque sommet marqué Spill.

Question 9.3. Écrivez une fonction remove\_from\_rig (rig : (reg, reg Set.t) Hashtbl.t) (v: reg) : unit qui supprime un sommet v du graphe d'interférence rig passé en paramètre.

Attention, étant donnée la représentation que l'on a choisi pour le graphe (sous forme de listes d'adjacence), supprimer un sommet nécessite de parcourir tous les éléments de la table de hachage pour retirer toute référence à ce sommet.

Question 9.4. Écrivez une fonction pick\_node\_with\_fewer\_than\_n\_neighbors (rig: (reg, reg Set.t) Hashtbl.t) (n: int): reg option qui renvoie Some(r), avec r un registre de rig possédant moins de n voisins quand c'est possible, et None sinon.

Question 9.5. Écrivez une fonction pick\_spilling\_candidate (rig : (reg, reg Set.t) Hashtbl.t) : reg option qui renvoie un sommet que l'on va évincer. Choisissez le sommet avec le maximum de voisins. Comme pour la fonction précédente, renvoyez Some(r) lorsque le

<sup>3.</sup> Chaitin, Gregory J.; Auslander, Marc A.; Chandra, Ashok K.; Cocke, John; Hopkins, Martin E.; Markstein, Peter W. (1981). "Register allocation via coloring".



graphe n'est pas vide ou None dans le cas contraire.

On vous fournit le type regalloc\_decision = Spill of reg | NoSpill of reg

Question 9.6. Écrivez la fonction récursive make\_stack (rig : (reg, reg Set.t) Hashtbl.t) (stack : regalloc\_decision list) (ncolors: int) : regalloc\_decision list qui à partir d'un graphe d'interférence, d'une pile de décision (déjà partiellement construite et éventuellement vide), d'un nombre de registres disponibles étend la pile passée en paramètre comme décrit plus haut.

```
Question 9.7. Écrivez la fonction allocate (allocation: (reg, loc) Hashtbl.t)
(rig: (reg, reg Set.t) Hashtbl.t) (all_colors: int Set.t) (next_stack_slot:
int) (decision: regalloc_decision) : int qui étend une allocation (éventuellement déjà
partiellement construite) à partir de :
    — alloc : une allocation partielle;
    — rig : le graphe d'interférence, utile pour connaître les voisins d'un sommet;
    — all_colors : un ensemble de registres physiques disponibles (les couleurs);
    — next_stack_slot : un entier (négatif ou nul comme expliqué plus haut) représentant le
    prochain slot à utiliser sur la pile (si besoin);
    — decision : une décision (de type regalloc_decision) stockée sur la pile de décision
Cette fonction renvoie le prochain emplacement sur la pile qu'il faudra utiliser dans le fu-
tur. Cela signifie qu'elle peut décrémenter la valeur next_stack_slot qu'on lui a passé en
paramètre.
```

Les fonctions make\_stack et allocate sont appelées par la fonction

qui vous est donnée déjà complétée. Cette fonction déroule l'allocation de registres pour une fonction d'un programme Linear. Elle renvoie un triplet contenant :

- 1. le graphe d'interférence qui peut être visualisé à partir de sa représentation en fichier .dot.
- 2. une table de hachage décrivant une association entre chaque pseudo-registre du programme en Linear et un emplacement;
- 3. la prochaine position libre sur la pile.

Cette fonction est elle-même appelée par la fonction regalloc lp lives all\_colors qui fait ce même travail mais sur un programme Linear complet (éventuellement composé de plusieurs fonctions).




```
$ ./main.native -f tests/basic/gcd.e -clever-regalloc -ltl-dump -
// In function main
// LinReg 1 allocated to a1
// LinReg 4 allocated to t2
// LinReg 3 allocated to s1
// LinReg 0 allocated to a0
// LinReg 2 allocated to t2
[...]
```

Dans la commande précédente, on a passé un certain nombre d'options :

- -clever-regalloc pour utiliser l'allocateur de registres que l'on vient de programmer.
- <u>-ltl-dump</u> pour afficher le programme LTL (pour comprendre à quoi correspondent les pseudo-registres)

Le graphe d'interférence est visible dans le fichier DOT tests/basic/gcd.rig et déjà converti en SVG pour vous dans tests/basic/gcd.rig.svg:



On y voit que les registres r2 et r4 sont alloués dans le même registre physique (t2, d'après le dump LTL précédent).

Les registres r3 et r4 sont dans des registres différents, parce qu'ils sont en interférence. Effectivement, on avait vu dans le dump Linear, quelques pages plus haut, que ces registres étaient vivants ensemble à un point de programme.

On ne voit pas les registres r0 et r1 dans ce graphe, qui correspondent aux arguments de la fonction. Effectivement, les arguments sont alloués dans des registres séparés (a0 à a7, puis sur la pile si nécessaire, mais à des offsets positifs par rapport à fp, depuis la fonction appelée), leur allocation sera faite automatiquement pour vous dans src/ltl\_gen.ml.

#### 9.3 Tester

Pour lancer les tests, vous avez utilisé depuis le début de ces séances de TP la commande make test. Mais vous ne connaissez pas toute la puissance qui se cache derrière cette commande!

Par défaut, make test lance le script Python tests/test.py sur l'ensemble des fichiers \*.e qui se trouvent dans le répertoire tests/basic. Aussi, par défaut, l'allocateur de registres « naïf » est utilisé.

Vous pouvez modifier ce comportement par défaut en passant des paramètres à votre commande make .



Pour passer des paramètres supplémentaires au compilateur (*i.e.* au ./main.native), on passe ces paramètres dans la variable OPTS de la manière suivante :

Pour lancer les tests sur un ensemble de fichiers source, on passe ces paramètres dans la variable de la manière suivante :

```
$ make test DIR="basic/prime.e basic/gcd.e"
# ...
./test.py -f basic/prime.e basic/gcd.e
2 threads running (['basic/prime.e', 'basic/gcd.e']).
All threads terminated!
2/2 OK.
0/2 KO : []
```

Vous pouvez évidemment combiner ces deux options :

```
$ make test OPTS=-clever-regalloc DIR="basic/prime.e basic/gcd.e"
# ...
./test.py -f basic/prime.e basic/gcd.e -clever-regalloc
# ...
```



# 10 Appels de fonctions

Le langage de votre compilateur est pour l'instant quelque peu limité. Notamment, on ne sait pas faire d'appels de fonctions. C'est la prochaine étape pour améliorer votre compilateur. Vous pourrez alors compiler des programmes qui ressemblent à celui-ci :

```
fib(n){
   if(n > 14){    return -1; }
   if(n <= 2){
      return 1;
   } else {
      return fib(n-1) + fib(n-2);
   }
}
main(n){
   return fib(n);
}</pre>
```

Comme vous le constatez, il s'agit d'une implémentation de la suite de Fibonacci de manière récursive et inefficace (on calcule plusieurs fois les mêmes valeurs...). Pour que les calculs ne durent pas trop longtemps, on abandonne et on renvoie -1 pour une entrée supérieure à 14.

Notons que pour le moment, nous n'avons toujours pas de type : toutes les variables sont entières. Le programme ci-dessus ainsi que 10 autres vous sont fournis dans le répertoire funcall.

Pour étendre votre compilateur, il va vous falloir modifier votre grammaire, ainsi que chacun des langages intermédiaires et des différentes passes de compilation. Voici un aperçu des changements à effectuer :

### 10.1 La grammaire

Une instruction peut maintenant être un appel de fonction (en plus des cas existants d'affectation, de boucles, ...) :

```
x = 3;

y = 8;

f(x,y); // Un appel de fonction, en tant qu'instruction.

z = x + y;
```

Une **expression** peut aussi contenir des appels de fonctions :

```
x = 3;

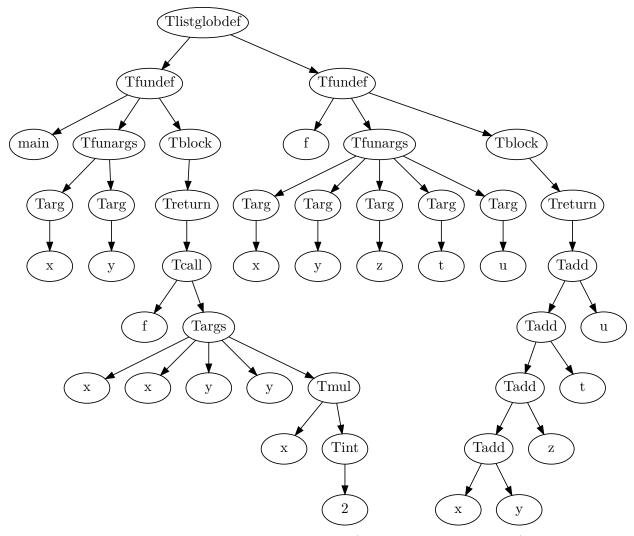
y = 8;

z = 5 * f(x,y) + 16; // Un appel de fonction, en tant qu'expression.
```

Étendez votre grammaire afin de reconnaître ces nouvelles constructions.

Écrivez également les actions correspondant à ces nouvelles constructions, de manière à obtenir un AST ressemblant à celui-ci :





Le programme source générant cet AST est le suivant (tests/funcall/5args.e):

```
main(x, y){
   return f(x,x,y,y,x*2);
}
f(x, y, z, t, u){
   return x + y + z + t + u;
}
```

Vous pouvez bien entendu ajouter au fichier src/ast.ml les nouveaux tags qui vous semblent nécessaires (Tcall, Targs...).

## 10.2 Le langage E

Étendez les types des expressions et des instruction E de la manière suivante, dans src/elang.ml.

```
type expr =
...
```



```
| Ecall of string * expr list

type instr =
...
| Icall of string * expr list
```

Une expression <code>Ecall(fname, args)</code> représente un appel de la fonction nommée <code>fname</code> avec les arguments représentés par la liste d'expressions <code>args</code>. La valeur de cette expression est la valeur de retour de la fonction <code>fname</code>. Si la fonction ne renvoie pas de valeur, il s'agit d'une erreur.

De manière similaire, une instruction <code>Icall(fname, args)</code> représente un appel de la fonction nommée <code>fname</code> avec les arguments représentés par la liste d'expressions <code>args</code>. La valeur de retour de la fonction est ignorée.

#### 10.2.1 Génération de E

Dans le fichier src/elang\_gen.ml, il vous faut maintenant traiter les nouveaux types de nœuds (Tcall, dans la figure précédente) introduits à la section précédente, afin de produire des expressions Ecall et des instructions Icall.

### 10.2.2 Interpréteur de E

Maintenant qu'une expression peut contenir des appels de fonctions, évaluer une expression peut nécessiter d'exécuter une fonction. Pour ce faire, vous allez avoir besoin d'écrire des définitions mutuellement récursives, c'est-à-dire que le corps de la fonction eval\_eexpr pourra faire appel à la fonction eval\_efun, qui appelle elle-même la fonction eval\_einstr, qui appelle elle-même la fonction eval\_eexpr...

La syntaxe OCaml pour écrire des définitions mutuellement récursive est la suivante :

```
let rec eval_eexpr st e = ...
and eval_einstr ... = ...
and eval efun ... = ...
```

Il vous faudra sans doute ajouter des arguments à ces fonctions, notamment eval\_eexpr.

À noter: pour le moment, les fonctions ne modifient pas la mémoire – les seuls effets de bords que l'on peut observer sont des affichages à l'écran. Pour autant, en prévision de l'avenir, on supposera que la mémoire peut être modifiée et on prendra donc garde à propager l'effet des appels de fonction sur l'état du programme. Plus concrètement, si vous devez évaluer une liste [e1; e2] d'expressions (par exemple pour évaluer les arguments d'une fonction), gardez bien en tête que l'évaluation de e1 pourrait modifier l'état et donc influencer l'évaluation de e2. Le type de retour de la fonction eval\_expr pourrait donc être étendu...

## 10.3 Le langage CFG

Comme pour le langage E, on ajoute un nouveau type d'expression <code>Ecall(fname, args)</code> et un nouveau type de nœud <code>Ccall(fname, args, s)</code> où s est le successeur de ce nœud, comme dans <code>Cassign</code>.



Les changements à effectuer dans src/cfg\_run.ml sont similaires à ceux que vous aurez effectués dans src/elang\_run.ml.

Comme vos types de données ont changé, le compilateur va se plaindre que vos match ne sont pas exhaustifs. Contentez le compilateur en complétant ces match.

#### 10.4 Le langage RTL

On introduit une opération Rcall of reg option \* string \* reg list.

L'opération Rcall(ord, fname, rargs) signifie qu'on appelle la fonction fname avec les arguments stockés dans les pseudo-registres rargs. Si ord = Some rd, le résultat de la fonction sera stocké dans le registre rd, sinon, si ord = None, le résultat de la fonction sera ignoré. Si org = Some rd mais que la fonction ne retourne pas de valeur, il s'agit d'une erreur.

### 10.5 Le langage LTL

La plus grande difficulté pour traiter les appels de fonction se situe dans l'émission de code assembleur (ou LTL, c'est presque la même chose).

En effet, à cet endroit, on doit être en mesure d'appeler une fonction (via l'instruction Lcall(fname)), déjà présente dans src/ltl.ml. Mais il faut aussi, et surtout émettre le code assembleur qui :

- 1. sauvegarde les registres dits *caller-save* (*i.e.* ceux qui doivent être sauvegardés par l'appelant) : en effet, la fonction appelée va peut-être (sûrement) utiliser ces registres pour faire un calcul, et leur valeur dans la fonction appelante serait perdue ;
- 2. fournit les arguments à la fonction;
- 3. effectue l'appel à proprement parler (instruction LCall);
- 4. récupère la valeur de retour de la fonction (stockée par convention dans le registre a0) à l'emplacement attendu (tel que calculé par l'allocation de registres);
- 5. restaure la valeur des registres caller-save.

Les modifications que vous devez effectuer se situent dans le fichier src/ltl\_gen.ml dans la fonction ltl\_instrs\_of\_linear\_instr, où vous devez traiter le cas où l'instruction Linear que vous devez traduire est Rcall(rd, callee\_fname, rargs).


#### 10.5.1 Sauvegarde des registres caller-save

Premièrement, il nous faut identifier l'ensemble des registres à sauvegarder. Une solution naïve consiste à sauvegarder tous les registres caller-save, à savoir les registres a0 à a7 et les registres t0 à t6. Dans votre code, cela s'écrirait arg\_register @ reg\_tmp.


Une solution plus économe serait de ne sauvegarder que les registres caller-save qui sont vivants après l'appel de fonction. Cette information est disponible via l'argument live\_out passé à la fonction ltl\_instrs\_of\_linear\_instr. L'ensemble des registres à sauvegarder est calculé par la fonction caller\_save, définie juste au-dessus de la fonction ltl\_instrs\_of\_linear\_instr. Cette fonction prend en paramètres :


- live\_out : le résultat de l'analyse de vivacité sur les arcs sortants;
- allocation: l'allocation de registres pour cette fonction;
- rargs : la liste des registres à passer en arguments.





(a) Organisation générale de la pile.





(c) Gestion des registres RTL alloués sur la pile par l'allocateur de registres.

FIGURE 5 – Gestion de la pile en LTL et RiscV à l'entrée dans une fonction.

La raison pour laquelle on passe la liste des registres arguments est la suivante. Rappelez-vous que les arguments d'une fonction sont passés dans les registres a0 à a7 : le premier argument dans a0, le second dans a1, etc. Supposons que l'on ait un appel de fonction Linear f(r1,r2), et que r1 soit associé au registre a1 et r2 au registre a0 (c'est possible si r1 et r2 sont les arguments de la fonction appelante, comme illustré par le test tests/funcall/argswap.e).

Alors, lors du passage de paramètre (l'étape suivante), on va vouloir écrire a1 dans a0 et a0 dans a1. Si on fait naïvement :

mv a0, a1
mv a1, a0

alors, il est évident que la valeur contenue dans a1 ne sera pas la bonne, elle aura été écrasée par le mv précédent.

C'est pourquoi la fonction caller\_save anticipe ce genre de problème, calcule l'ensemble des arguments qui vont être écrasés (fonction overwritten\_args) et les inclue dans l'ensemble des registres à sauvegarder.


Maintenant que les registres à sauvegarder sont identifiés, il faut émettre les instructions qui les sauvegardent. La fonction save\_callee\_save fait ce travail, et prend en paramètres :

- to\_save : ltl\_reg list : l'ensemble des variables à sauvegarder (on vient de le calculer!);
- ofs : int : le numéro du premier emplacement sur la pile disponible pour effectuer cette sauvegarde.

Si on reprend le schéma de la pile de la section précédente, et qu'on le complète.

L'emplacement prévu pour les sauvegardes de registres se situe à l'adresse pointée par s0, moins l'espace réservé aux registres évincés (spillés), moins l'espace réservé aux variables locales de la fonction.





(b) Passage des arguments surnuméraires

FIGURE 6 – Gestion de la pile en LTL et RiscV lors de l'appel d'une fonction.

Nous n'avons pas encore de variables locales à une fonction que nous stockons sur la pile, il nous suffit donc d'avoir le nombre de variables évincés, que l'on à notre disposition dans le paramètre num\_spilled de la fonction ltl\_instrs\_of\_linear\_instr.

La fonction save\_caller\_save renvoie un triplet (save\_regs\_instructions, arg\_saved, ofs), où:

- save\_regs\_instructions : ltl\_instr list est la liste des instructions LTL qui se chargent de sauvegarder les registres to\_save sur la pile;
- arg\_saved : (ltl\_reg \* int) list est une liste d'association : une paire (r, o) dans cette liste signifie que le registre LTL r a été sauvegardé à l'emplacement o de la pile (ofs pour le premier, ofs 1 pour le deuxième, etc.)
- ofs est le nouveau premier emplacement disponible sur la pile, après avoir sauvegardé les registres. Nous en aurons besoin pour la suite.

Après cette liste d'instructions, une série d'écritures à des adresses so - X ont été émises. Il faut à présent positionner le pointeur de pile sp juste après les registres sauvegardés : c'est là qu'on utilise la valeur ofs retournée par la fonction save\_caller\_save.

#### 10.5.2 Passage des paramètres

Vient ensuite le moment du passage des paramètres. La fonction pass\_parameters, bien nommée, se charge de cette tâche. Elle prend en arguments :

- rargs : reg list : la liste des pseudo-registres RTL/Linear qui contiennent les arguments ;
- allocation : l'allocation de registres ;
- arg\_saved : le résultat de save\_caller\_save, pour savoir où sont sauvegardés, si nécessaire, les arguments.

Elle peut échouer si certains registres de rargs ne sont pas alloués dans allocation. Si elle réussit, elle renvoie une paire (parameter\_passing\_instructions, npush), où :

 parameter\_passing\_instructions est une liste d'instructions LTL, qui effectuent le passage des paramètres;



— npush est le nombre d'arguments qu'on a du passer sur la pile. (La plupart du temps, les arguments iront dans les registres a0-7, mais pour des fonctions avec plus de 8 arguments (comme dans tests/funcall/lots\_of\_args.e par exemple), on utilisera la pile.)

Si nécessaire, cette fonction effectue des « push » sur la pile, c'est-à-dire qu'elle décrémente le registre sp et écrit à l'adresse obtenue.

#### 10.5.3 Appel de la fonction

Ici, c'est très simple, il suffit d'émettre l'instruction LTL LCall callee\_fname, où callee\_fname est le nom de la fonction appelée.

#### 10.5.4 Dépilement des arguments

On restaure le pointeur de pile sp juste avant les arguments, *i.e.* on replace le pointeur de pile npush emplacements plus haut dans la pile.

#### 10.5.5 Valeur de retour

La valeur de retour de la fonction est stockée dans a0, reportez-là à l'emplacement désiré (rd), si nécessaire.

#### 10.5.6 Restauration des registres caller-save

Pour finir, il s'agit de restaurer la valeur des registres que l'on a sauvegardés. La fonction restore\_caller\_save calcule la liste des instructions qui effectuent cette tâche; elle prend en argument une liste d'association comme celle renvoyée par save\_caller\_save.

Attention, si l'emplacement correspondant au registre dans lequel on doit stocker la valeur de retour est un registre physique, il ne faudra pas restaurer la valeur de ce registre!

#### 10.6 Fonctions built-in

Maintenant que vous êtes capables de gérer des appels de fonctions, vous remarquerez que l'instruction print est en fait un cas particulier d'appel de fonction. On peut donc supprimer l'instruction print de notre compilateur pour la transformer en un simple appel de fonction.

Voici les endroits où vous devrez apporter des modifications :

- le lexer : le token SYM\_PRINT n'a plus de raison d'être.
- la grammaire : un cas particulier n'est plus nécessaire.
- chacun des langages intermédiaires : plus besoin d'instruction dédiée à l'affichage!
- les interpréteurs de chacun de ces langages intermédiaires : on utilisera le mécanisme de built-in!

Le fichier src/builtins.ml contient un certain nombre de fonctions built-in prédéfinies pour vous. En particulier, la fonction do\_builtin oc mem fname vargs donne la sémantique de l'appel de la fonction built-in dont le nom est fname avec les arguments donnés dans vargs. Le paramètre oc est un output channel comme vous en avez déjà manipulé jusqu'ici. Le paramètre mem, de type Mem.t est une mémoire, dont vous n'avez pas encore eu besoin (mais très bientôt, promis!). Dans les interpréteurs des différents langages, vous pouvez passer la mémoire associée à l'état st comme ceci : st.mem.

Cette fonction a comme type de retour int option res:



- OK (Some i) signifie que la fonction s'est évaluée sans erreur et retourne la valeur entière i.
- OK None signifie que la fonction s'est évaluée sans erreur et ne retourne pas de valeur.
- Error msg signifie que la fonction s'est évaluée avec l'erreur msg.



## 11 Typage

Le but de cette extension de votre compilateur est d'ajouter des types à votre langage. Dans un premier temps, nous nous restreindrons aux type **int**, **char** et **void**. Dans les extensions ultérieures, nous ajouterons des pointeurs, des tableaux, des structures.

Un nouvel ensemble de fichiers de tests vous est proposé : les répertoires tests/type\_basic/, tests/type\_funcall/ et tests/char/. Jetez un œil à certains de ces fichiers avant de continuer votre lecture, pour vous familiariser avec le nouveau langage que vous allez devoir compiler.

Les types sont un concept de haut-niveau : c'est-à-dire qu'ils n'impactent que les quelques premiers langages intermédiaires. Dans notre cas, vous n'aurez qu'à modifier votre grammaire expr\_grammar\_action.g et les fichiers relatifs au langage E.

Pour commencer, ajoutez au fichier src/prog.ml les définitions suivantes :

```
type typ =
    Tint
    | Tchar
    | Tvoid

let string_of_typ t =
    match t with
    | Tint -> "int"
    | Tchar -> "char"
    | Tvoid -> "void"
```

On définit ainsi un type typ qui correspond aux différents types que nous allons supporter dans un premier temps. On définit également une fonction d'affichage de ces types.

Voici un aperçu des étapes que vous devrez franchir. Celles-ci sont volontairement peu détaillées pour laisser libre cours à votre imagination!

- 1. Modifiez votre grammaire pour supporter :
  - les types dans les signatures de fonction : type de retour et types des arguments
  - les déclarations de variables locales, suivies ou non, d'une initialisation (e.g. int x; ou int x = 3 \* z;)
  - les caractères litéraux : char c = 'A';
- 2. Ajoutez les définitions de tags nécessaires à src/ast.ml.
- 3. Ajoutez un constructeur Echar of char aux expressions de E (src/elang.ml).
- 4. Modifiez le type des fonctions efun dans src/elang.ml pour faire en sorte que :
  - funargs soit dorénavant une liste de string \* typ, pour retenir le type des arguments;
  - un nouveau champ funvartyp : (string, typ) Hashtbl.t enregistre le type de chaque variable locale;
  - un nouveau champ funrettype : typ donne le type de retour de la fonction.
- 5. Dans src/elang\_gen.ml, écrivez une fonction type\_expr (typ\_var : (string,typ) Hashtbl.t) (typ\_fun : (string, typ list \* typ) Hashtbl.t) (e: expr) : typ res qui calcule le type d'une expression.

  Les paramètres :
  - typ\_var donne le type de chaque variable locale de la fonction courante.



- typ\_fun donne la signature (type des arguments + type de retour) de chaque fonction déjà traitée dans le programme.
- e est l'expression à typer.

La fonction renvoie une erreur, notamment si une variable ou une fonction apparaissant dans l'expression n'a pas de type connu.

- 6. Toujours dans src/elang\_gen.ml, ajoutez les paramètres typ\_var et typ\_fun aux fonctions make\_eexpr\_of\_ast et make\_einstr\_of\_ast. Vérifiez (avec un appel à type\_expr) que les expressions construites ont un type, avant de les renvoyer dans make\_eexpr\_of\_ast.
  - Dans make\_einstr\_of\_ast, vérifiez que lors d'une affectation v = e, la variable v et l'expression e ont des types compatibles. (int et char sont compatibles, int et void non). (Écrivez une fonction séparée pour tester la compatibilité de 2 types.)
  - Toujours dans make\_einstr\_of\_ast, mettez à jour typ\_var lorsque vous rencontrez une déclaration de variable. Vérifiez au passage qu'on ne déclare pas de variable de type void.
  - Lors d'appels de fonctions (que ce soit comme une expression <code>Ecall</code> ou une instruction <code>Icall</code>), vérifiez que les arguments sont du type attendu (comparez avec la signature que vous pouvez obtenir via <code>typ\_fun</code>).
- 7. Dans la fonction make\_fundef\_of\_ast, initialisez une table typ\_var puis mettez à jour la table typ\_fun que vous devrez recevoir en argument.
- 8. Dans la fonction make\_eprog\_of\_ast, initialisez la table fun\_typ en y insérant notamment le type de trois fonctions built-in utiles :

```
let fun_typ = Hashtbl.create (List.length 1) in
Hashtbl.replace fun_typ "print" ([Tint], Tvoid);
Hashtbl.replace fun_typ "print_int" ([Tint], Tvoid);
Hashtbl.replace fun_typ "print_char" ([Tchar], Tvoid);
```

9. On remarque qu'il faut avoir défini une fonction pour qu'on puisse l'appeler dans une autre. (Le typage devrait échouer si ce n'est pas le cas.)

Comment gérer les fonctions mutuellement récursives? Regardez les fichiers tests/type\_funcall/mutrec.e et tests/type\_funcall/mutrec-hotstadter.e. Ils contiennent des déclarations de fonctions. Faites-en sorte de traiter ces fichiers convenablement. (L'évaluation du fichier tests/type\_funcall/mutrec-hotstadter.e prend un certain temps...)



# A Installation des dépendances

Dès le début, vous aurez besoin d'OCAML.

```
# Install opam
$ sudo apt install opam # ou avec votre gestionnaire de paquets favori
$ opam --version
2.0.4 # Assurez-vous d'avoir au moins opam version 2.0...
$ opam init
$ opam switch install 4.08.0 (ou plus)
# Installation des dépendances
$ opam install stdlib-shims ocamlbuild ocamlfind menhir lwt logs batteries yojson websocket

→ websocket-lwt-unix
$ eval $(opam env)
```

Pour assembler un programme RISC-V, vous aurez besoin d'outils spécifiques :

- riscv64-unknown-elf-gcc : un cross-compilateur pour RISC-V pour générer des exécutables RISC-V,
- qemu-riscv64 : un émulateur de RISC-V pour les exécuter.

Sur des Debian (11+) ou Ubuntu (19.04+):

```
\ sudo apt-get install git build-essential gdb-multiarch qemu-system-misc gcc-riscv64-linux-gnu \ \hookrightarrow \  binutils-riscv64-linux-gnu
```

Sur ArchLinux:

```
 \begin{tabular}{ll} $sudo pacman -S riscv64-linux-gnu-binutils riscv64-linux-gnu-gcc riscv64-linux-gnu-gdb \\ $\hookrightarrow$ qemu-arch-extra \\ \end{tabular}
```

Si vous devez compiler vous-mêmes : (attention c'est long!)

```
$ git clone --recursive https://github.com/riscv/riscv-gnu-toolchain
# install dependencies
$ sudo apt-get install autoconf automake autotools-dev curl libmpc-dev libmpfr-dev libgmp-dev gawk
\hookrightarrow build-essential bison flex texinfo gperf libtool patchutils bc zlib1g-dev libexpat-dev
# configure and build (vous pouvez changer le préfixe, c'est ici que seront installés les outils)
$ cd riscv-gnu-toolchain
$ ./configure --prefix=/usr/local
$ sudo make
# OFMU:
$ wget https://download.qemu.org/qemu-4.1.0.tar.xz
$ tar xf qemu-4.1.0.tar.xz
# install dependencies
$ sudo apt-get install pkg-config libglib2.0-dev libpixman-1-dev
# configure and build (vous pouvez changer le préfixe, c'est ici que seront installés les outils)
$ ./configure --disable-kvm --disable-werror --prefix=/usr/local
$ make
$ sudo make install
```



# B Merlin, l'assistant de programmation OCaml

Merlin est un assistant à la programmation OCaml pouvant s'interfacer avec de nombreux éditeurs de code tels que Emacs, Vim, Atom, Visual Studio Code, Sublime Text ...Vous pouvez trouver le dépôt Github de Merlin à l'URL suivante : https://github.com/ocaml/merlin.

#### B.1 Installation de Merlin

Avec Opam:

```
$ opam install merlin
$ opam user-setup install # configure Emacs et Vim pour Merlin
```

Manuellement: Instructions et sources sur le dépôt Github

#### B.2 Merlin et Visual Studio Code

Les instructions sont tirés du blog suivant : https://www.cosmiccode.blog/blog/vscode-for-ocaml/

```
1. $ opam install merlin $ opam install ocp-ident # Outil d'indentation de code OCaml
```

2. Dans VSCode chercher et installer l'extension OCaml and Reason IDE

#### Remarques:

— VSCode ne trouve pas les modules définis dans d'autres fichiers.

Pour que VSCode reconnaisse les modules provenant des autres fichiers, il faut au préalable avoir compilé ces modules. Pour cela, exécutez la commande make dans la source du projet. Les modules compilés seront stockés dans le dossier src/\_build.

— Si les outils OCaml ne sont pas accessibles globalement.

VSCode n'arrivera pas à trouver les outils de l'environnement OCaml-Merlin, il est possible de les spécifier de la manière suivante

- Ctrl+P > Workspace Settings
- Extensions  $\rightarrow$  Reason configuration
- Spécifier les chemins vers les binaires ocamlmerlin, ocamlfind, ocp-ident et opam